Inferencia Estadística: Bootstrapping (Remuestreo y Variabilidad Empírica)

Corte 1

Diana C. Moreno Ch.

El Problema de la Variabilidad Muestral

Inferencia Estadística Tradicional

Queremos estimar un parámetro desconocido de la población (θ) utilizando un estimador ($\hat{\theta}$) calculado a partir de una muestra de tamaño n.

La Variabilidad Muestral

Si tomáramos otra muestra de la misma población, el valor de $\hat{\theta}$ cambiaría. Esta fluctuación se conoce como **variabilidad muestral** y determina la precisión de nuestra estimación.

El Desafío Práctico

En la vida real solo tenemos **una sola muestra**. ¿Cómo podemos medir la variabilidad de $\hat{\theta}$ sin necesidad de recolectar nuevas muestras de la población?

La Idea del Remuestreo (Resampling)

El Principio del Plug-in (Efron, 1979)

Dado que no tenemos acceso a la población general F, utilizamos la **muestra observada** $(\hat{F}_n)$ como una representación empírica de la población.

La Idea del Remuestreo (Resampling)

Mundo Real (Inaccesible)

$$\text{Población } F \xrightarrow{\text{Muestreo}} \text{Muestra } X \to \hat{\theta}$$

Imposible de repetir muchas veces por costo o tiempo.

Mundo Bootstrap (Simulado)

$$\text{Muestra } X \xrightarrow{\text{Remuestreo}} \text{Muestra } X^* \to \hat{\theta}^*$$

Podemos simular este proceso miles de veces en una computadora.

¿Qué es una Muestra Bootstrap?

¿Qué es una Muestra Bootstrap?

Una **muestra bootstrap** $X^* = (x_1^*, x_2^*, \ldots, x_n^*)$ es un nuevo conjunto de datos de tamaño n obtenido mediante **muestreo con reemplazo** a partir de la muestra original $X = (x_1, x_2, \ldots, x_n)$.

¿Qué es una Muestra Bootstrap?

Propiedades Matemáticas del Remuestreo

Al elegir con reemplazo cada uno de los n elementos:

- Un elemento original puede aparecer **cero, una o varias veces** en la muestra X^*.
- Probabilidad de que una observación **no** sea seleccionada en una extracción: $1 - \frac{1}{n}$.
- En el límite ($n \to \infty$), la proporción de elementos no seleccionados (*Out-Of-Bag* o OOB) es:

$$\lim_{n\to\infty} \left(1 - \frac{1}{n}\right)^n = \frac{1}{e} \approx 36.8\,\%$$

- Por lo tanto, cada muestra bootstrap contiene aprox. el **63.2 %** de los datos únicos originales.

Algoritmo de Bootstrapping Paso a Paso

Procedimiento de Simulación

1. **Muestra Original:** Iniciar con la muestra $X = (x_1, \ldots, x_n)$ y calcular el estadístico de interés $\hat{\theta}$.
2. **Generación de Muestras:** Extraer B muestras bootstrap independientes mediante remuestreo con reemplazo:

$$X^{*1}, X^{*2}, \ldots, X^{*B}$$

3. **Cálculo del Estadístico:** Calcular la estimación para cada muestra bootstrap:

$$\hat{\theta}^{*1}, \hat{\theta}^{*2}, \ldots, \hat{\theta}^{*B}$$

4. **Distribución Empírica:** Utilizar el conjunto de estimaciones $\{\hat{\theta}^{*b}\}_{b=1}^{B}$ para aproximar la **distribución muestral** de $\hat{\theta}$.

Interpretación: Estimación Empírica de la Variabilidad

La Función de Distribución Empírica (eCDF)

- En la inferencia clásica, asumimos una distribución poblacional teórica F (ej. Normal, Poisson).
- En Bootstrapping, reemplazamos la población desconocida F por la **Función de Distribución Empírica** $\hat{F}_n$, la cual asigna una probabilidad igual a $1/n$ a cada dato observado en la muestra.

Medición Directa de la Incertidumbre

- En lugar de derivar fórmulas matemáticas complejas para el error estándar de $\hat{\theta}$, **simulamos el proceso de muestreo directamente desde nuestros datos**.
- La variabilidad de $\hat{\theta}^*$ respecto a $\hat{\theta}$ **imita** la variabilidad de $\hat{\theta}$ respecto al verdadero parámetro poblacional θ.

La Analogía Fundamental de la Variabilidad

Mundo Poblacional(Teórico / Inobservable)

$$\theta \longrightarrow X \longrightarrow \hat{\theta}$$

- **Parámetro real:** θ
- **Estimador:** $\hat{\theta}$
- **Variabilidad teórica:**

$$\text{Var}_F(\hat{\theta}) = \mathbb{E}_F\left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2\right]$$

- Requiere supuestos o muestras muy grandes.

La Analogía Fundamental de la Variabilidad

Mundo Bootstrap (Empírico / Computable)

$$\hat{\theta} \longrightarrow X^* \longrightarrow \hat{\theta}^*$$

- **Parámetro de referencia:** $\hat{\theta}$
- **Estimador bootstrap:** $\hat{\theta}^*$
- **Variabilidad empírica:**

$$\text{Var}_{\hat{F}_n}(\hat{\theta}^*) \approx \frac{1}{B-1}\sum_{b=1}^{B}(\hat{\theta}^{*b} - \bar{\theta}^*)^2$$

- Se calcula por aproximación Monte Carlo.

Interpretación Práctica de los Resultados

¿Cómo interpretar la dispersión empírica de $\hat{\theta}^*$?

La desviación estándar de las B estimaciones bootstrap ($\widehat{SE}_{\text{boot}}$) representa la **sensibilidad del estadístico** ante variaciones en la muestra observada.

Interpretación Práctica de los Resultados

Ventajas de la Varianza Empírica

- **Estadísticos complejos:** Permite medir variabilidad en la mediana, cuantiles o coeficientes Gini (donde no hay fórmula teórica fácil).
- **Sin supuestos rígidos:** Captura asimetrías o colas pesadas de la muestra real.

Intuición Final

El Bootstrap no crea información nueva,

extrae la información de variabilidad

que ya está contenida en la muestra.

Aplicaciones del Remuestreo en Machine Learning

Control de la Variabilidad en Modelos

El remuestreo bootstrap es la base de las técnicas de **Ensemble Learning** para reducir la varianza de modelos de predicción.

Bagging (Bootstrap Aggregating)

- Entrena B modelos independientes en B muestras bootstrap.
- Promedia las predicciones para estabilizar el modelo y reducir varianza.

Random Forest & OOB

- Extiende Bagging agregando selección aleatoria de características.
- Usa las observaciones **Out-Of-Bag (36.8 %)** para validar el modelo sin necesidad de validación cruzada extra.

1 Bibliografía

Actividad Práctica: Experimento en R

Objetivo

Construir la **distribución bootstrap de la media** a partir de una muestra pequeña y compararla con la **distribución muestral teórica**.

Actividad Práctica: Experimento en R

Diseño del Experimento

- **Población teórica:** $N(\mu = 50, \sigma = 10)$.
- **Muestra inicial:** $n = 15$.
- **Réplicas Bootstrap:** $B = 100$.

Comparación Teórica

Por el Teorema del Límite Central, la distribución muestral teórica de la media es:

$$\bar{X} \sim N\left(50, \frac{10}{\sqrt{15}}\right)$$

Error Estándar Teórico $SE \approx 2.58$

Implementación en R: Simulación Bootstrap

Código R: Generación de Muestras y Re-muestreo

```
# 1. Parámetros iniciales y muestra pequeña (n = 15)
set.seed(10082026)
n <- 15
mu_teorica <- 50
sd_teorica <- 10

# Generamos la muestra observada original
muestra_orig <- rnorm(n,
mean = mu_teorica,
sd = sd_teorica)
```

Implementación en R: Simulación Bootstrap

Código R: Generación de Muestras y Re-muestreo

```
# 2. Experimento Bootstrap: B = 100 re-muestreos
B <- 100
medias_boot <- replicate(B, {
  muestra_boot <- sample(muestra_orig,
   size = n,
   replace = TRUE)
  mean(muestra_boot)
})
```

Implementación en R: Comparación Gráfica

Código R: Histograma vs. Curva Normal Teórica

```
# 3. Graficar la distribución empírica bootstrap
hist(medias_boot, probability = TRUE,
main = "Bootstrap vs Teórica",
     xlab = "Media muestral",
     col = "lightblue", border = "white")

# Densidad kernel de la distribución bootstrap
lines(density(medias_boot), col = "blue", lwd = 2)
```

Implementación en R: Comparación Gráfica

Código R: Histograma vs. Curva Normal Teórica

```
# Curva de la Distribución Muestral Teórica
se_teorico <- sd_teorica / sqrt(n)
curve(dnorm(x, mean = mu_teorica, sd = se_teorico),
      add = TRUE, col = "red", lwd = 2, lty = 2)

legend("topright",
legend = c("Bootstrap (Empírica)", "Normal Teórica"),
       col = c("blue", "red"), lty = c(1, 2), lwd = 2)
```

Análisis de Resultados: Bootstrap vs. Teórica

Observaciones ($B = 100$ y $n = 15$)

- **Centro de la distribución:** La media bootstrap se centra en torno a la media de la *muestra observada* ($\bar{x}$), no necesariamente en μ.
- **Discretización / Varianza:** Con $B = 100$ la curva empírica muestra cierta variabilidad en comparación con la curva teórica.

Conclusión Clave

- El método bootstrap aproxima con éxito el **error estándar** (la variabilidad) sin asumir la distribución de la población.
- Incrementar B (ej. $B = 1000$) suaviza la aproximación empírica.

1 Bibliografía

Bibliografía

1. https://rpubs.com/jstats1702/1361982
2. Wackerly, D. D., Mendenhall III, W., Scheaffer, R. L., & Yescas Milanés, J. (2002). Estadística matemática con aplicaciones.
3. Walpole, R. E., Myers, R. H., & Myers, S. L. (1999). Probabilidad y estadística para ingenieros. Pearson Educación.