Inferencia Estadística

Regresión lineal simple

Diana C. Moreno Ch.

Índice General

1 Medidas de Asociación

Índice General

1. Medidas de Asociación
2. Modelo de regresión lineal simple

Índice General

1. Medidas de Asociación
2. Modelo de regresión lineal simple
3. Inferencia sobre el modelo

Índice General

1. Medidas de Asociación
2. Modelo de regresión lineal simple
3. Inferencia sobre el modelo
4. Análisis de Varianza para la regresión lineal

Índice General

1. Medidas de Asociación
2. Modelo de regresión lineal simple
3. Inferencia sobre el modelo
4. Análisis de Varianza para la regresión lineal
5. Supuestos sobre los errores

Gráfica para dos variables cuantitativas

Relación entre las dos variables

1. ¿Qué tipo de modelo se muestra?
2. ¿Qué tan fuerte es el modelo?
3. ¿Hay algunas observaciones poco comunes?

Correlación y regresión

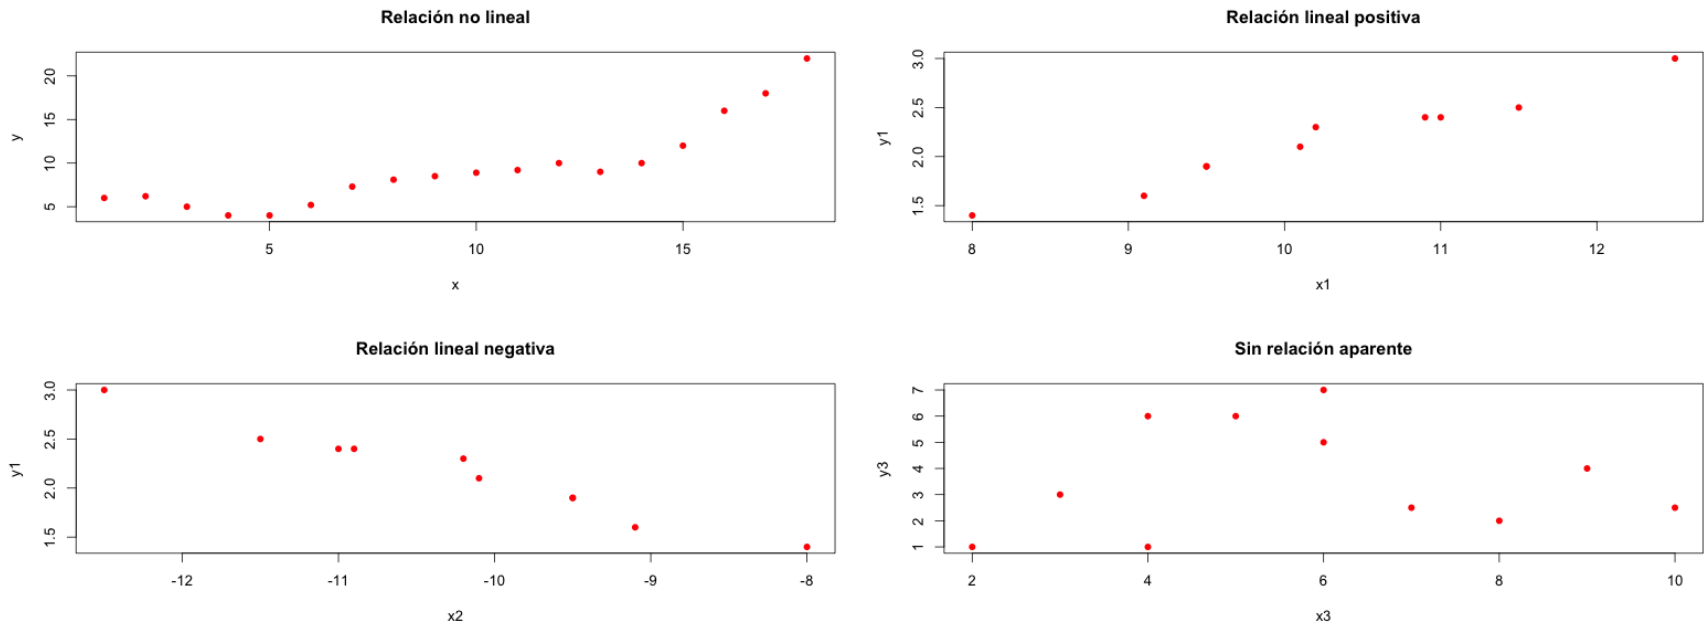
Variables que se vinculan

Variable Dependiente es la variable que se predice o calcula. Cuya representación es Y.

Variable Independiente es la variables que proporcionan las bases para el cálculo. Cuya letra de representación es: X.

Gráfica para dos variables cuantitativas

Diagrama de dispersión



1 Medidas de Asociación

2 Modelo de regresión lineal simple

3 Inferencia sobre el modelo

4 Análisis de Varianza para la regresión lineal

5 Supuestos sobre los errores

Medida de asociación lineal

La asociación lineal puede medirse en la población con la covarianza y el coeficiente de correlación lineal de pearson.

Covarianza

$$Cov(X,Y) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

Nos indica si la posible relación entre dos variables es directa o inversa.

- Directa $Cov(X,Y) > 0$
- Inversa $Cov(X,Y) < 0$

El signo de la covarianza nos dice si el aspecto de la nube de puntos es creciente o no, pero no nos dice nada sobre el grado de relación entre las variables

Correlación

Definición

Se puede definir la correlación cómo la medida estadística que sirve para evaluar la intensidad de la asociación entre dos o más variables cuantitativas.[a]

El principal objetivo del análisis de correlación consiste en determinar qué tan fuerte es la relación entre las variables.

[a] Estadística Básica para Ingenieros,Luis María Dicovskiy Riobóo

Medidas numéricas

Coeficiente de correlación lineal de pearson

$$\rho(X,Y) = \frac{Cov(X,Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}}$$

$Var(X), Var(Y)$ finitas

Propiedades

- Es adimensional
- Sólo toma valores en [-1,1]
- Relación lineal perfecta entre dos variables $\rho = +1 o \rho = -1$
- Cuanto más cerca esté ρ de $+1 o -1$ mejor será el grado de relación lineal

Ejemplo

Se recolectan datos de una muestra de 10 restaurantes ubicados cerca al campus universitario, de la población de estudiantes en miles y ventas trimestrales en miles de dólares.

pobl.estudiantes	2	6	8	8	12	16	20	20	22	26
ventas.trimestrales	58	105	88	118	117	137	157	169	149	202

Ejemplo

Ejemplo

1. Identificar la variable dependiente e independiente
2. Realizar un diagrama de dispersión
3. Calcular la covarianza y el coeficiente de correlación lineal de Pearson e interpretarlo

1 Medidas de Asociación

2 Modelo de regresión lineal simple

3 Inferencia sobre el modelo

4 Análisis de Varianza para la regresión lineal

5 Supuestos sobre los errores

Modelo de regresión lineal simple

Modelo de regresión lineal simple

$$y = \beta_0 + \beta_1 x + \epsilon$$

β_0 y β_1 se conocen como los parámetros del modelo, y ϵ (la letra griega épsilón) es una variable aleatoria que se conoce como término del error.

Correlación y regresión

Ecuación de regresión lineal simple

$$E(y) = \beta_0 + \beta_1 x$$

$\beta_0 =$ coordenada de la intersección con el eje y

$\beta_1 =$ pendiente de la recta

$E(y) =$ *es la media o valor esperado de y para un valor dado de x.*

Modelo de Regresión lineal simple

Ecuación de regresión lineal simple estimada

$$\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}; \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Modelo de Regresión lineal simple

Ecuación de regresión lineal simple estimada

$$\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}; \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Mínimos cuadrados

Para estimar β_0 y β_1 se utiliza el método de **Mínimos cuadrados**, que consiste en encontrar aquellos valores de β_0 y de β_1 que hagan mínima la suma de los cuadrados de las desviaciones de las observaciones, respecto de la recta que representa el modelo, en el sentido vertical.

Modelo de Regresión lineal simple

Algunas propiedades de los estimadores de mínimos cuadrados

1. Los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ son insesgados.
2. Si ϵ_i $i = 1, ..., n$ está distribuído normalmente entonces $\hat{\beta}_0$ y $\hat{\beta}_1$ están distribuídos normalmente.

Modelo de Regresión lineal simple

Coeficiente de determinación

$$r^2 = \frac{SCR}{SCT} * 100$$

donde
$SCE = \sum(y_i - \hat{y}_i)^2$, suma de cuadrados del error
$SCR = \sum(\hat{y}_i - \bar{y})^2$, suma de cuadrados de la regresión
$SCT = \sum(y_i - \bar{y})^2$, suma de cuadrados total

r^2 mide la proporción de variación en y que se explica por la variable independiente x en el modelo de regresión.

1 Medidas de Asociación

2 Modelo de regresión lineal simple

3 Inferencia sobre el modelo

4 Análisis de Varianza para la regresión lineal

5 Supuestos sobre los errores

Inferencia sobre la pendiente β_1

Prueba t

$$H_0 : \beta_1 = 0 \qquad vs \qquad H_1 : \beta_1 \neq 0$$

El estadístico de prueba:

$$t_c = \frac{\hat{\beta}_1 - \beta_1}{s_{\hat{\beta}_1}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{CME/s_{xx}}}$$

sigue una distribución t con $n-2$ grados de libertad. Donde

$$s_{\hat{\beta}_1} = \frac{s}{\sqrt{\sum(x_i - \bar{x})^2}}$$

- **Método del p-valor:** Rechazar H_0 si p-valor$< \alpha$
- **Método del valor crítico:** Rechazar H_0 si $t < -t_{\alpha/2}$ o si $t > t_{\alpha/2}$

Modelo de Regresión lineal simple

Intervalo de confianza para β_1

$$\hat{\beta}_1 - t_{\alpha/2} s_{\hat{\beta}_1} \leq \beta_1 \leq \hat{\beta}_1 + t_{\alpha/2} s_{\hat{\beta}_1}$$

Inferencia sobre el modelo

Prueba F

Si la hipótesis nula es verdadera, CMR y CME son dos estimaciones independientes de σ^2 y la distribución muestral de CMR/CME sigue una distribución F con $gl_1 = 1$ y $gl_2 = n - 2$.

$$H_0 : \beta_1 = 0 \qquad vs \qquad H_1 : \beta_1 \neq 0$$

El estadístico de prueba es

$$F_c = \frac{CMR}{CME}$$

Inferencias respecto a β_0

Prueba de hipótesis respecto a la intersección

1. $$H_0 : \beta_0 = 0 \qquad vs \qquad H_1 : \beta_0 \neq 0$$
2. El estadístico de prueba es
$$t_c = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{CME \sum x_i^2 / n s_{xx}}}$$
3. Método de rechazo
   - **Método del p-valor:** Rechazar H_0 si p-valor$< \alpha$
   - **Método del valor crítico:** Rechazar H_0 si $t < -t_{\alpha/2}$ o si $t > t_{\alpha/2}$

Inferencias respecto a β_0.

Prueba de hipótesis respecto a la intersección

$$\hat{\beta}_0 - t_{\alpha/2}(SE) \leq \beta_0 \leq \hat{\beta}_0 + t_{\alpha/2}(SE)$$

$$SE = \sqrt{CME \sum x_i^2 / nS_{xx}}$$

1 Medidas de Asociación

2 Modelo de regresión lineal simple

3 Inferencia sobre el modelo

4 Análisis de Varianza para la regresión lineal

5 Supuestos sobre los errores

Análisis de Varianza para la regresión lineal

Análisis de Varianza para la regresión lineal

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado medio	F	P-valor
Regresión	SCR	1	CMR	$F = \frac{CMR}{CME}$	
Error	SCE	$n-2$	CME		
Total	STC	$n-1$			

1 Medidas de Asociación

2 Modelo de regresión lineal simple

3 Inferencia sobre el modelo

4 Análisis de Varianza para la regresión lineal

5 Supuestos sobre los errores

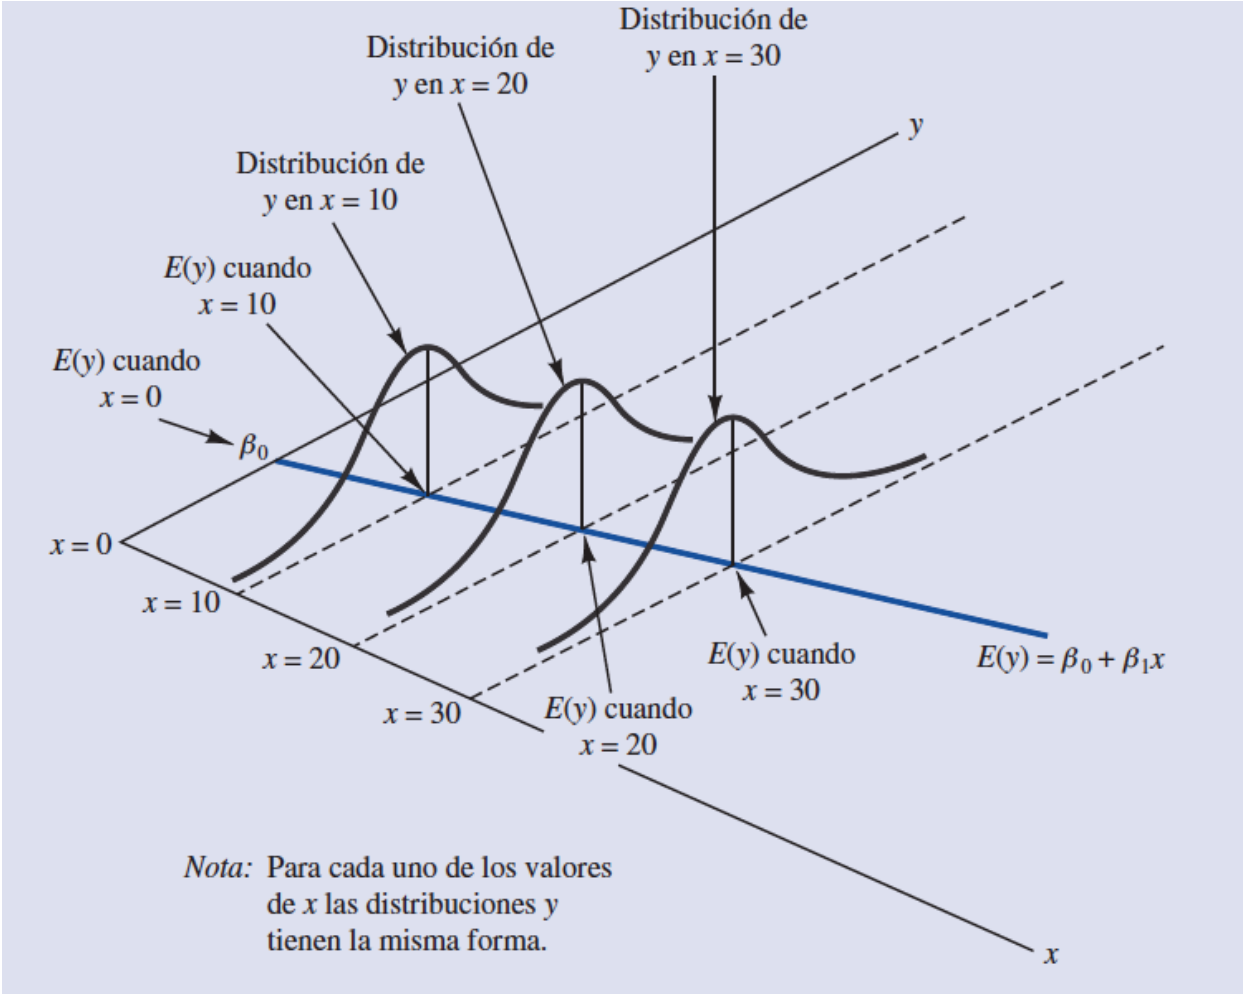
Modelo de Regresión lineal simple

Suposiciones del modelo

Las pruebas de significancia en el análisis de regresión están basadas en las suposiciones siguientes acerca del término del error ϵ.

1. El término del error es una variable aleatoria cuya media, o valor esperado, es cero; es decir, $E(\epsilon) = 0$.
2. La varianza de ϵ, que se denota σ^2, es la misma para todos los valores de x.
3. Los valores de ϵ son independientes.
4. El término del error ϵ es una variable aleatoria distribuida normalmente

Modelo de Regresión lineal simple



Análisis residual: confirmación de las suposiciones del modelo

Residual de la observación i.

El análisis residual es la herramienta principal para determinar si el modelo de regresión empleado es apropiado.

$$\epsilon_i = y_i - \hat{y}_i$$

Residuales estandarizados

Residual estandarizado de la observación

$$\frac{y_i - \hat{y}_i}{s_{y_i - \hat{y}_i}}$$

La gráfica de los residuales estandarizados permite ver si la suposición de que el término del error ϵ tiene distribución normal es correcta.

Supuesto de normalidad

1. H_0:Los errores se distribuyen normal.
   H_1:Los errores NO se distribuyen normal.
2. El estadístico de prueba es:
   W, Shapiro Wilk
3. Método de rechazo
   Método del p-valor: Rechazar H_0 si p-valor$< \alpha$

Supuesto de homogeneidad o varianza contante

1. H_0:La varianza de los errores es la misma.
   H_1:La varianza de los errores NO es la misma.
2. El estadístico de prueba es:
   BP, Breusch-Pagan
3. Método de rechazo
   Método del p-valor: Rechazar H_0 si p-valor$< \alpha$

Supuesto de independencia

1. H_0:Los errores son independientes.
   H_1:La errores NO son independientes.
2. El estadístico de prueba es:
   DW, Durbin-Watson
3. Método de rechazo
   Método del p-valor: Rechazar H_0 si p-valor$< \alpha$

Ejercicio

Se recolectan datos de una muestra de 10 restaurantes ubicados cerca al campus universitario, de la población de estudiantes en miles y ventas trimestrales en miles de dólares.

pobl.estudiantes	2	6	8	8	12	16	20	20	22	26
ventas.trimestrales	58	105	88	118	117	137	157	169	149	202

Bibliografía

1. Anderson D.,Sweeney D.,Williams T., Estadística para administración y Economía 10 edición. 2008 CENGAGE LEARNING.
2. Mendenhall William/Beaver Robert/Beaver Bárbara Introducción a la probabilidad y estadística. Décimo segunda edición. 2008. CENGAGE LEARNING.
3. WALPOLE & MYERS. Probabilidad y Estadística para Ingeniería y Ciencias
4. David R. A.,Dennis J. S.,Thomas A. W., Estadística para administración y economía.10a. edición. 2008