Inferencia Estadística

Parcial 2 (Corte 2) · Guía de estudio desde cero

Universidad Externado de Colombia · Ciencia de Datos · 2026-2
Parcial: viernes 16 de octubre

Qué es esta guía

Es todo el corte 2 explicado desde cero, en el orden en que te conviene estudiarlo. Está armada con tus materiales: las diapositivas y guías de la profe Diana Moreno, tus cuadernos del 12 de agosto al 2 de octubre, los scripts de R del curso, los tres preparciales del corte 2 y el Parcial 2 de 2024-2. Cada sección sigue la metodología de la profe (los 5 pasos de las pruebas, la notación e.p./m.e. de los intervalos y su manera de redactar conclusiones).

La complementa el otro PDF, la **Guía de solución**, que resuelve paso a paso todos los ejercicios de los preparciales y del parcial viejo.

Cómo usarla

1. Sigue los bloques del plan de abajo. Cada uno dura máximo 3 horas.
2. En cada bloque lee primero la teoría con lápiz en mano. Rehaz los ejemplos tú mismo antes de mirar el resultado.
3. Después intenta los ejercicios del preparcial que se indican. Dale **10 minutos sin mirar** a cada uno antes de abrir la Guía de solución.
4. Las cajas rojas (*¡Ojo!*) son las trampas donde más se pierden puntos. El Externado no regala nada, así que esas cajas valen oro.
5. El viernes en la mañana repasa solo la última sección (hoja de trampas y fórmulas).

> **Sobre R**
>
> Uso solo funciones que aparecen en tus scripts o en tus cuadernos (`t.test`, `var.test`, `prop.test`, `qnorm`, `pt`, `qchisq`, `normtol.int`, `boot`, `power.t.test`, `cohen.d`, etc.). Para cargar y filtrar bases hacen falta básicos como `read.csv`, `$` o `[ ]`, que no son "soluciones" sino manejo de datos. Las pocas funciones que no salen ni en scripts ni en cuadernos (por ejemplo `qf`, que sí está en la guía de IC de la profe) van marcadas con su alternativa permitida.

Cómo es el parcial (lo que dicen los exámenes)

El Parcial 2 de 2024-2 tenía dos partes, y los preparciales de 2026-2 siguen la misma lógica, ahora con pruebas de hipótesis:

- **Parte práctica (R con una base de datos).** Te dan un `.csv` (en 2024 fue `Audiometry.csv`) y piden intervalos o pruebas sobre subgrupos. Por ejemplo, "mujeres mayores de 30" o "hombres vs. mujeres". Siempre preguntan además *qué supuestos* usaste.
- **Parte teórica (a mano).** Demostraciones sobre estimadores: consistencia, MLE, sesgo, ECM, eficiencia, suficiencia, momentos.
- **Lo nuevo de 2026-2 (preparcial parte 3):** leer salidas de R y completar espacios, verdadero/falso sobre p-valor y potencia, tamaño del efecto (d de Cohen), potencia, Monte Carlo y bootstrap.

Tema	Dónde aparece en los exámenes	Peso probable
Estimadores (sesgo, ECM, eficiencia, consistencia, suficiencia, momentos, MLE)	Preparcial parte 1 (9 ejercicios), Parcial 2024 (puntos 3 y 4)	Muy alto
IC con R sobre una base	Preparcial parte 2 (#2, #5, #21–24), Parcial 2024 (#1, #2)	Muy alto
Pruebas de hipótesis (con y sin R)	Preparcial parte 3 (#1–#8)	Muy alto
IC a mano con fórmulas	Preparcial parte 2 (#1, #12–#20)	Alto
Lectura de salidas de R	Preparcial parte 3 (#4), cuadernos	Alto
Predicción y tolerancia	Preparcial parte 2 (#3, #4), parte 3 (#10, #11)	Alto
Potencia, tamaño del efecto, V/F	Preparcial parte 3 (#6–#8)	Alto
Monte Carlo (cobertura)	Preparcial parte 2 (#8–#11), parte 3 (#9)	Medio
Bootstrap	Preparcial parte 2 (#6, #7), script de clase	Medio

Plan de estudio (bloques de máximo 3 horas)

Bloque	Cuándo	Dura	Qué estudias	Qué practicas
0	Martes noche (opcional)	30 min	Sección 1: lo mínimo de probabilidad	Nada, solo leer
1	Miércoles	3 h	Sección 2: estimadores	Preparcial parte 1 (#1–#9) y Parcial 2024 (#3, #4)
2	Miércoles (después del taller)	3 h	Sección 3: intervalos (IC, predicción, tolerancia, bootstrap, Monte Carlo)	Preparcial parte 2: #1, #3, #12–#24 primero; luego #2, #5, #6, #8–#11
3	Jueves	3 h	Sección 4: pruebas de hipótesis, potencia, efecto	Preparcial parte 3: #3, #4, #6, #7, #8, luego #1, #2, #5
4	Jueves (tarde/noche)	2.5–3 h	Sección 5: R, bases y salidas + simulacro	Parcial 2024 completo con cronómetro (100 min) + retos de la sección 6
5	Viernes temprano	30–45 min	Sección 7: hoja de trampas	Nada nuevo: solo repasar

Cómo repartir cada bloque de 3 horas

0:00 – 0:50	Teoría de la sección, rehaciendo los ejemplos a mano.
0:50 – 1:00	Pausa (lejos del celular).
1:00 – 2:20	Ejercicios del preparcial, primero solo y luego comparando con la Guía de solución.
2:20 – 2:30	Pausa.
2:30 – 3:00	Autoevaluación: las preguntas rápidas del final de la sección y una lista de lo que aún no entiendes.

Si te queda poco tiempo

Prioriza en este orden: (1) MLE y propiedades de estimadores, (2) IC y PH con `t.test` / `prop.test` / `var.test` sobre una base, (3) lectura de salidas y V/F de p-valor y potencia, (4) predicción y tolerancia, (5) Monte Carlo y bootstrap.

Índice general

Cómo es el parcial **2**

Plan de estudio **3**

1 Lo mínimo de probabilidad que necesitas (Bloque 0) **7**

1.1 El juego de la inferencia . . . 7
1.2 Reglas de esperanza y varianza (las vas a usar en todo) . . . 7
1.3 Tabla de distribuciones (media y varianza) . . . 8
1.4 Las cuatro distribuciones muestrales que sostienen todo el corte . . . 8
1.5 Estadísticos de orden (salen en estimadores) . . . 8
1.6 Probabilidades y cuantiles en R . . . 9

2 Estimadores (Bloque 1) **10**

2.1 Qué es un estimador . . . 10
2.2 Sesgo y error cuadrático medio . . . 10
2.3 Eficiencia relativa . . . 11
2.4 Consistencia . . . 12
2.5 Suficiencia . . . 12
2.6 Método de momentos . . . 13
2.7 Máxima verosimilitud (MLE) . . . 14
2.8 Monte Carlo para estudiar estimadores (script `sep18.R`) . . . 15
2.9 Autoevaluación del Bloque 1 . . . 15

3 Intervalos (Bloque 2) **15**

3.1 La idea de un intervalo de confianza . . . 15
3.2 Anatomía de un IC (notación de la profe) . . . 16
3.3 Método del pivote (de dónde salen las fórmulas) . . . 16
3.4 ¿Qué fórmula uso? Árbol de decisión . . . 17
3.5 Una población, caso por caso . . . 18
3.5.1 Media con σ conocida (z) . . . 18
3.5.2 Media con σ desconocida (t) . . . 18
3.5.3 Proporción . . . 19
3.5.4 Varianza y desviación estándar . . . 19
3.6 Dos poblaciones, caso por caso . . . 19

3.6.1 Cómo leer un IC de diferencia (cuaderno 11 sep) . . . 19
3.6.2 Medias con σ_1, σ_2 conocidas . . . 20
3.6.3 Medias con varianzas desconocidas: primero el cociente . . . 20
3.6.4 Pareadas . . . 20
3.6.5 Diferencia de proporciones . . . 20
3.6.6 Cociente de varianzas cuando solo te dan s_1, s_2 . . . 21
3.7 Problemas "al revés" (muy del Externado) . . . 21
3.8 Intervalo de predicción y límites de tolerancia . . . 21
3.9 Bootstrap: intervalos sin suponer normalidad . . . 22
3.10 Monte Carlo: ¿el intervalo cumple lo que promete? . . . 24
3.11 Autoevaluación del Bloque 2 . . . 24

4 Pruebas de hipótesis (Bloque 3) 25
4.1 La idea: un juicio . . . 25
4.2 Plantear las hipótesis a partir del texto . . . 25
4.3 Los 5 pasos de la profe . . . 26
4.3.1 Regla de decisión: punto crítico y p-valor . . . 26
4.4 Errores tipo I y II, potencia . . . 27
4.5 El p-valor, sin enredos . . . 27
4.6 Catálogo de pruebas (con la tabla de fórmulas de la profe) . . . 28
4.6.1 Varianzas . . . 29
4.7 Leer salidas de R (aparece seguro) . . . 29
4.8 Relación entre IC y prueba . . . 30
4.9 Significancia estadística vs. sustantiva: tamaño del efecto . . . 30
4.10 Potencia con R . . . 31
4.11 Bootstrap y permutación en contrastes . . . 31
4.12 Autoevaluación del Bloque 3 . . . 31

5 R para el parcial: bases, plantillas y simulacro (Bloque 4) 32
5.1 Funciones que puedes usar . . . 32
5.2 Cargar cada base sin sustos . . . 32
5.3 Filtrar, separar grupos y contar . . . 33
5.4 Plantillas listas para copiar . . . 34
5.5 ¿Y el supuesto de normalidad? . . . 34
5.6 Simulacro (Bloque 4) . . . 35

6 Retos tipo Externado (con respuesta) 35

7 Hoja de trampas para el viernes (Bloque 5) 38

7.1 Las 25 trampas que más puntos cuestan 38

7.2 Fórmulas en una página 39

7.3 Frases de respuesta (copia el estilo) 39

1 Lo mínimo de probabilidad que necesitas (Bloque 0)

1.1 El juego de la inferencia

Hay una **población** que no podemos ver completa (todos los asegurados, todos los estudiantes que presentaron el ICFES, todas las botellas que saldrán de la máquina). Esa población tiene números fijos pero desconocidos, los **parámetros**. Los más comunes son la media μ, la varianza σ^2 y la proporción p. En general se escriben θ.

Tomamos una **muestra** de tamaño n y con ella calculamos **estadísticos**: $\bar{x}$, s^2, $\hat{p}$. En general se escriben $\hat{\theta}$ ("theta gorro"). La idea central del curso es esta:

> **Idea clave**
>
> Un parámetro θ es **fijo** (no cambia). Un estadístico $\hat{\theta}$ es **aleatorio**: si tomas otra muestra, te da otro número. Toda la inferencia consiste en medir *cuánto se mueve* $\hat{\theta}$ de muestra a muestra, para decir algo confiable sobre θ.

1.2 Reglas de esperanza y varianza (las vas a usar en todo)

Esperanza (promedio teórico)	Varianza (dispersión teórica)
$\mathrm{E}(aX+b) = a\,\mathrm{E}(X) + b$	$\mathrm{V}(aX+b) = a^2\,\mathrm{V}(X)$ (la b desaparece y la a sale *al cuadrado*)
$\mathrm{E}(X_1+\cdots+X_n) = \mathrm{E}(X_1)+\cdots+\mathrm{E}(X_n)$ siempre	$\mathrm{V}(X_1+\cdots+X_n) = \mathrm{V}(X_1)+\cdots+\mathrm{V}(X_n)$ *solo si son independientes*
$\mathrm{E}(X-Y) = \mathrm{E}(X) - \mathrm{E}(Y)$	$\mathrm{V}(X-Y) = \mathrm{V}(X) + \mathrm{V}(Y)$ (independientes). **Se suman.**
$\mathrm{V}(X) = \mathrm{E}(X^2) - [\mathrm{E}(X)]^2 \quad\Longrightarrow\quad \mathrm{E}(X^2) = \mathrm{V}(X) + [\mathrm{E}(X)]^2$	

Para una muestra aleatoria $Y_1, \ldots, Y_n$ de una población con media μ y varianza σ^2:

$$\mathrm{E}(\bar{Y}) = \mu, \qquad \mathrm{V}(\bar{Y}) = \frac{\sigma^2}{n}, \qquad \mathrm{SE}(\bar{Y}) = \frac{\sigma}{\sqrt{n}}.$$

El **error estándar** (SE) es la desviación estándar de un estimador: cuánto se mueve de muestra a muestra.

> **¡Ojo! · La varianza de una diferencia**
>
> $\mathrm{V}(\bar{X}-\bar{Y}) = \dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}$. **Suma**, nunca resta. De ahí sale el $\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}$ de todos los intervalos y pruebas de dos muestras.

1.3 Tabla de distribuciones (media y varianza)

Distribución	Densidad / prob.	$\mathrm{E}(Y)$	$\mathrm{V}(Y)$
Bernoulli(p)	$p^y(1-p)^{1-y},\ y\in\{0,1\}$	p	$p(1-p)$
Binomial(n,p)	$\binom{n}{y}p^y(1-p)^{n-y}$	np	$np(1-p)$
Poisson(λ)	$\lambda^y e^{-\lambda}/y!$	λ	λ
Uniforme(a,b)	$1/(b-a),\ a\le y\le b$	$(a+b)/2$	$(b-a)^2/12$
Exponencial (media θ)	$\frac{1}{\theta}e^{-y/\theta},\ y>0$	θ	θ^2
Gamma(α,β)	$\frac{y^{\alpha-1}e^{-y/\beta}}{\beta^\alpha\Gamma(\alpha)}$	$\alpha\beta$	$\alpha\beta^2$
Normal(μ,σ^2)	$\frac{1}{\sqrt{2\pi\sigma^2}}e^{-(y-\mu)^2/(2\sigma^2)}$	μ	σ^2
Ji-cuadrado (ν gl)	—	ν	2ν

¡Ojo! · Leer bien la parametrización

En este curso la exponencial se escribe con **media** θ: $f(y)=\frac{1}{\theta}e^{-y/\theta}$. Entonces $\mathrm{E}(Y)=\theta$ y $\mathrm{V}(Y)=\theta^2$. Si en el examen aparece $\lambda e^{-\lambda y}$, la media es $1/\lambda$. La densidad $f(x)=\frac{x}{\theta^2}e^{-x/\theta}$ es una Gamma$(2,\theta)$: media 2θ, varianza $2\theta^2$.

1.4 Las cuatro distribuciones muestrales que sostienen todo el corte

Cada intervalo y cada prueba del corte sale de una de estas cuatro "cantidades pivote":

Cantidad	Distribución	Cuándo vale
$Z=\dfrac{\bar X-\mu}{\sigma/\sqrt{n}}$	$N(0,1)$	Población normal, o n grande (TLC); σ conocida
$T=\dfrac{\bar X-\mu}{S/\sqrt{n}}$	t con $n-1$ gl	Población normal, σ desconocida
$\chi^2=\dfrac{(n-1)S^2}{\sigma^2}$	χ^2 con $n-1$ gl	Población normal
$F=\dfrac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$	F con $(n_1-1,\ n_2-1)$ gl	Dos poblaciones normales independientes
$Z=\dfrac{\hat p-p}{\sqrt{p(1-p)/n}}$	$\approx N(0,1)$	$np\ge 5$ y $n(1-p)\ge 5$

1.5 Estadísticos de orden (salen en estimadores)

$Y_{(n)}=\max(Y_1,\dots,Y_n)$ y $Y_{(1)}=\min(Y_1,\dots,Y_n)$. Si las Y_i son independientes con densidad f y acumulada F:

$$f_{(n)}(y)=n\,[F(y)]^{n-1}f(y),\qquad f_{(1)}(y)=n\,[1-F(y)]^{n-1}f(y).$$

Dos resultados que conviene saber de memoria

- Máximo de una $U(0,\theta)$: $f_{(n)}(y) = \dfrac{n\,y^{n-1}}{\theta^n}$, $\mathrm{E}(Y_{(n)}) = \dfrac{n\theta}{n+1}$, $\mathrm{V}(Y_{(n)}) = \dfrac{n\theta^2}{(n+1)^2(n+2)}$ (cuaderno del 31 de agosto).
- Mínimo de n exponenciales con media θ: $P(Y_{(1)} > y) = \left(e^{-y/\theta}\right)^n = e^{-ny/\theta}$, así que $Y_{(1)}$ es exponencial con media θ/n.

1.6 Probabilidades y cuantiles en R

Quiero...	En R
$P(Z \le z)$ (área a la izquierda)	`pnorm(z)`
$P(Z > z)$ (área a la derecha)	`pnorm(z, lower.tail = FALSE)`
$P(T \le t)$, $P(T > t)$ con gl	`pt(t, gl)`, `pt(t, gl, lower.tail = FALSE)`
$P(\chi^2 > c)$	`pchisq(c, gl, lower.tail = FALSE)`
El z que deja $\alpha/2$ a la derecha	`qnorm(alpha/2, lower.tail = FALSE)` o `abs(qnorm(alpha/2))`
El t que deja $\alpha/2$ a la derecha	`abs(qt(alpha/2, gl))` (así lo hace la profe)
Cuantiles de χ^2	`qchisq(alpha/2, gl)` (pequeño) y `qchisq(1-alpha/2, gl)` (grande)
Cuantil de F	`qf(1-alpha/2, gl1, gl2)` (está en la guía de IC de la profe)

Confianza $1-\alpha$	90%	92%	93%	95%	98%	99%
$z_{\alpha/2}$	1.645	1.751	1.812	1.960	2.326	2.576

¡Ojo! · La notación de los cuantiles

La tabla de fórmulas de la profe usa "cola inferior": $\chi^2_{1-\alpha/2}$ es el cuantil *grande* (`qchisq(1-alpha/2, gl)`). En las diapositivas a veces se usa "cola superior" y el mismo número se llama $\chi^2_{\alpha/2}$. Para no enredarte, piensa siempre en R: el **grande** va con el límite **inferior** del IC de la varianza, y el **pequeño** con el superior. Con z y t usa el valor absoluto, como hace la profe: `abs(qnorm(0.025))` $= 1.96$.

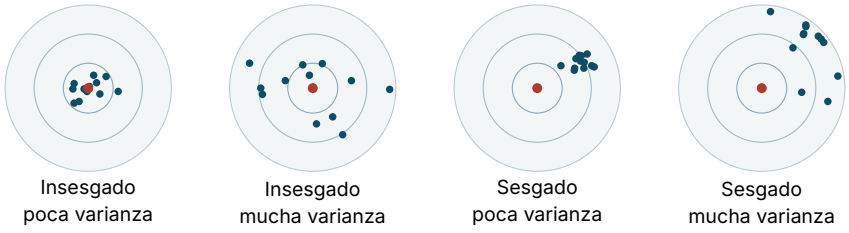
2 Estimadores (Bloque 1)

2.1 Qué es un estimador

Un **estimador** es una regla, casi siempre una fórmula, que dice cómo calcular un número con los datos de la muestra para aproximar un parámetro. Ejemplos: $\bar{Y}$ para μ, S^2 para σ^2, $\hat{p} = Y/n$ para p, $2\bar{Y}$ o $Y_{(n)}$ para el θ de una uniforme.

> **¡Ojo! · Un estimador no puede contener el parámetro**
> $\bar{Y} - \theta$ **no** es un estimador porque no lo puedes calcular sin conocer θ. $\bar{Y} - \frac{1}{2}$ sí lo es.

Para juzgar si un estimador es bueno se miran dos cosas. La primera es si en promedio le atina (**sesgo**). La segunda es qué tanto se dispersa de muestra a muestra (**varianza**). Piensa en tiro al blanco, donde el centro es θ y cada punto es el $\hat{\theta}$ de una muestra distinta:



El punto rojo es θ. Cada punto azul es el $\hat{\theta}$ de una muestra distinta.

2.2 Sesgo y error cuadrático medio

Insesgado	$\mathrm{E}(\hat{\theta}) = \theta$
Sesgo	$\mathrm{B}(\hat{\theta}) = \mathrm{E}(\hat{\theta}) - \theta$
Error cuadrático medio	$\mathrm{ECM}(\hat{\theta}) = \mathrm{E}[(\hat{\theta} - \theta)^2] = \mathrm{V}(\hat{\theta}) + [\mathrm{B}(\hat{\theta})]^2$
Si es insesgado	$\mathrm{ECM}(\hat{\theta}) = \mathrm{V}(\hat{\theta})$. Si es sesgado, $\mathrm{ECM}(\hat{\theta}) > \mathrm{V}(\hat{\theta})$.

> **Receta: ¿es insesgado?**
> 1. Escribe $\hat{\theta}$ en función de las Y_i, por ejemplo $\hat{\theta} = \frac{Y_1 + 2Y_2}{3}$.
> 2. Saca E usando linealidad: las constantes salen y la esperanza de una suma es la suma de esperanzas.
> 3. Reemplaza $\mathrm{E}(Y_i)$ por lo que dice la tabla de distribuciones.
> 4. Compara con θ. Si da θ, es insesgado. Si no, el sesgo es $\mathrm{E}(\hat{\theta}) - \theta$.

> **Corregir un sesgo (cuaderno del 21 de agosto)**
> Si $\mathrm{E}(\hat{\theta}) = a\theta + b$, entonces $\mathrm{B}(\hat{\theta}) = a\theta + b - \theta = \theta(a-1) + b$. Para volverlo insesgado despejas θ:

$\mathrm{E}\left(\frac{\hat\theta - b}{a}\right) = \theta$, así que $\hat\theta^* = \dfrac{\hat\theta - b}{a}$. Como es insesgado,

$$\mathrm{ECM}(\hat\theta^*) = \mathrm{V}(\hat\theta^*) = \mathrm{V}\left(\frac{\hat\theta - b}{a}\right) = \frac{1}{a^2}\,\mathrm{V}(\hat\theta).$$

S^2 es insesgado (cuaderno del 21 de agosto)

Con la identidad $\sum(Y_i - \bar Y)^2 = \sum Y_i^2 - n\bar Y^2$, más $\mathrm{E}(Y_i^2) = \sigma^2 + \mu^2$ y $\mathrm{E}(\bar Y^2) = \frac{\sigma^2}{n} + \mu^2$:

$$\mathrm{E}(S^2) = \frac{1}{n-1}\left[\sum \mathrm{E}(Y_i^2) - n\,\mathrm{E}(\bar Y^2)\right] = \tfrac{1}{n-1}\left[n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2\right] = \tfrac{(n-1)\sigma^2}{n-1} = \sigma^2.$$

En cambio, el estimador que divide por n, $\hat\sigma^2 = \frac{1}{n}\sum(Y_i - \bar Y)^2 = \frac{n-1}{n}S^2$, cumple $\mathrm{E}(\hat\sigma^2) = \frac{n-1}{n}\sigma^2$. Está **sesgado**, con $\mathrm{B} = -\sigma^2/n$. Ese es justamente el MLE de la normal.

Error de estimación y su límite. El error de estimación es $\varepsilon = |\hat\theta - \theta|$. Si $\hat\theta$ es aproximadamente normal, $P(\varepsilon < 2\ \mathrm{SE}(\hat\theta)) \approx 0.95$. Por eso $b = 2$ SE se usa como "límite del error". *Cuaderno 21 ago:* con $n = 1000$ y $y = 560$ votantes, $\hat p = 0.56$, $\mathrm{SE} = \sqrt{0.56 \cdot 0.44/1000} = 0.0157$ y $b = 0.0314$. Se lee así: "la probabilidad de que la distancia entre $\hat p$ y el verdadero p sea máximo 0.03 es del 95%".

2.3 Eficiencia relativa

Entre dos estimadores **insesgados** se prefiere el de menor varianza. La profe define:

$$\boxed{\mathrm{eff}(\hat\theta_1, \hat\theta_2) = \frac{\mathrm{V}(\hat\theta_2)}{\mathrm{V}(\hat\theta_1)}} \qquad \begin{cases} \mathrm{eff} < 1 & \Rightarrow \mathrm{V}(\hat\theta_2) < \mathrm{V}(\hat\theta_1) \Rightarrow \text{ "nos quedamos con } \hat\theta_2\text{"} \\ \mathrm{eff} > 1 & \Rightarrow \mathrm{V}(\hat\theta_1) < \mathrm{V}(\hat\theta_2) \Rightarrow \text{ "nos quedamos con } \hat\theta_1\text{"} \end{cases}$$

Mediana vs. media en una normal (cuaderno 21 ago)

$\hat\theta_1$ = mediana, con $\mathrm{V} = (1.2533)^2\sigma^2/n$, y $\hat\theta_2 = \bar X$, con $\mathrm{V} = \sigma^2/n$. Entonces $\mathrm{eff} = \frac{\sigma^2/n}{1.2533^2\sigma^2/n} = 0.6366 < 1$, así que nos quedamos con $\bar X$. La varianza de la media es el 63.66% de la de la mediana.

Uniforme $(0, \theta)$ (cuaderno 31 ago)

$\hat\theta_1 = 2\bar Y$ tiene $\mathrm{V}(\hat\theta_1) = 4 \cdot \frac{\theta^2/12}{n} = \frac{\theta^2}{3n}$. $\hat\theta_2 = \frac{n+1}{n}Y_{(n)}$ tiene $\mathrm{V}(\hat\theta_2) = \left(\frac{n+1}{n}\right)^2 \frac{n\theta^2}{(n+1)^2(n+2)} = \frac{\theta^2}{n(n+2)}$. $\mathrm{eff}(\hat\theta_1, \hat\theta_2) = \frac{\theta^2/[n(n+2)]}{\theta^2/(3n)} = \frac{3}{n+2} < 1$ para $n > 1$. Nos quedamos con $\hat\theta_2$, el que usa el máximo.

¡Ojo! · Tres errores comunes con la eficiencia

1. Invertir la fracción. Con la convención de la profe **el numerador es la varianza del segundo**.
2. Concluir sin mirar n: la eficiencia puede depender de n. En el preparcial (parte 1, #3) un estimador gana para $n \le 7$ y el otro para $n \ge 8$.
3. Comparar por varianza estimadores sesgados. En ese caso se compara el ECM.

2.4 Consistencia

Un estimador es consistente si, cuando n crece, se pega cada vez más al verdadero θ.

Receta: demostrar consistencia

Definición de la profe: si $\hat{\theta}_n$ es insesgado y $\lim_{n\to\infty} \mathrm{V}(\hat{\theta}_n) = 0$, entonces es consistente.

1. Calcula $\mathrm{E}(\hat{\theta}_n)$ y muestra que es θ.
2. Calcula $\mathrm{V}(\hat{\theta}_n)$ usando independencia: $\mathrm{V}(\sum Y_i) = \sum \mathrm{V}(Y_i)$.
3. Toma el límite cuando $n \to \infty$ y verifica que da 0.

Si el estimador es **sesgado**, basta mostrar que el sesgo $\to 0$ *y* que la varianza $\to 0$ (equivale a ECM $\to 0$).

Ejemplos de clase

- $\bar{Y}$: $\mathrm{E}(\bar{Y}) = \mu$ y $\mathrm{V}(\bar{Y}) = \sigma^2/n \to 0$, así que es consistente para μ.
- Y/n con $Y \sim \mathrm{Bin}(n, p)$: $\mathrm{E} = p$ y $\mathrm{V} = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n} \to 0$, así que es consistente para p.
- $\bar{X} - \bar{Y}$ con muestras independientes: $\mathrm{E} = \mu_1 - \mu_2$ y $\mathrm{V} = \frac{\sigma_1^2+\sigma_2^2}{n} \to 0$, así que es consistente para $\mu_1 - \mu_2$.
- $\hat{\sigma}^2 = \frac{n-1}{n} S^2$ es sesgado, pero su sesgo $-\sigma^2/n \to 0$ y su varianza $\to 0$. También es consistente.

Teorema útil: si $\hat{\theta}_n \to \theta$ y $\hat{\theta}'_n \to \theta'$ son consistentes, entonces $\hat{\theta}_n + \hat{\theta}'_n$, $\hat{\theta}_n \hat{\theta}'_n$ y $\hat{\theta}_n / \hat{\theta}'_n$ (con $\hat{\theta}'_n \neq 0$) son consistentes para $\theta + \theta'$, $\theta\theta'$ y θ/θ'.

2.5 Suficiencia

Un estadístico U es **suficiente** para θ si resume toda la información que la muestra trae sobre θ. Una vez conoces U, el resto de los datos no dice nada más sobre θ. En la práctica se demuestra con el teorema de factorización:

$$\boxed{L(\theta) = L(y_1, \ldots, y_n \mid \theta) = g(u, \theta) \times h(y_1, \ldots, y_n)}$$

donde g depende de los datos **solo a través de** u, y h **no depende de** θ.

Receta: demostrar suficiencia

1. Escribe la verosimilitud como producto: $L(\theta) = \prod_{i=1}^{n} f(y_i \mid \theta)$.
2. Simplifica el producto: $\prod a = a^n$, $\prod e^{b_i} = e^{\sum b_i}$, $\prod y_i^{\theta} = (\prod y_i)^{\theta}$, $\prod p^{y_i} = p^{\sum y_i}$.
3. Separa: todo lo que tenga θ va en g y debe quedar en función de un solo resumen u ($\sum y_i$, $\bar{y}$, $\max y_i$…). Lo que no tenga θ va en h.
4. Concluye: "$U = \ldots$ es un estadístico suficiente para θ".

Exponencial (cuaderno 31 ago)

$$L(\theta) = \prod_{i=1}^{n} \frac{1}{\theta} e^{-y_i/\theta} = \left(\frac{1}{\theta}\right)^n e^{-\sum y_i/\theta} = \underbrace{\theta^{-n} e^{-n\bar{y}/\theta}}_{g(\bar{y},\theta)} \cdot \underbrace{1}_{h}.$$

Por tanto $\bar{Y}$ (y también $\sum Y_i$) es suficiente para θ.

Bernoulli, Poisson y normal con σ^2 conocida

- Bernoulli: $L(p) = p^{\sum x_i}(1-p)^{n-\sum x_i} \cdot 1$, así que $\sum X_i$ es suficiente.
- Poisson: $L(\lambda) = \prod \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \underbrace{\lambda^{\sum x_i} e^{-n\lambda}}_{g} \cdot \underbrace{\frac{1}{\prod x_i!}}_{h}$, así que $T = \sum X_i$ es suficiente.
- Normal (σ^2 conocida): $L(\mu) = (2\pi\sigma^2)^{-n/2} \exp\{-\frac{1}{2\sigma^2}\sum(x_i-\mu)^2\}$. Al expandir, $\sum(x_i-\mu)^2 = \sum x_i^2 - 2\mu\sum x_i + n\mu^2$, y queda $\underbrace{\exp\{\frac{\mu\sum x_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}\}}_{g(\sum x_i,\mu)} \cdot \underbrace{(2\pi\sigma^2)^{-n/2}\exp\{-\frac{\sum x_i^2}{2\sigma^2}\}}_{h}$. $\bar{X}$ es suficiente.

¡Ojo! · Cuando el soporte depende de θ

En la $U(0,\theta)$ no olvides la indicadora: $L(\theta) = \theta^{-n}\,\mathbb{I}(y_{(n)} \le \theta)$. Como θ aparece junto al **máximo**, el suficiente es $Y_{(n)}$, no $\bar{Y}$. Y si te preguntan "¿este estimador es suficiente?" y la parte con θ no se puede escribir solo con ese resumen, la respuesta es **no**. Por ejemplo, $\prod(\theta - x_i)$ depende de todos los x_i, no solo de su suma.

2.6 Método de momentos

La idea es igualar los momentos teóricos con los muestrales:

$$\mu_k' = \mathrm{E}(Y^k) \qquad \text{con} \qquad m_k' = \frac{1}{n}\sum_{i=1}^{n} Y_i^k, \qquad k = 1, 2, \ldots, \text{ tantas ecuaciones como parámetros.}$$

Receta: momentos

1. Calcula $\mathrm{E}(Y)$ en función del parámetro, con la tabla o con $\int y f(y)\,dy$.
2. Iguala: $\mathrm{E}(Y) = \bar{y}$. Si hay dos parámetros, agrega $\mathrm{E}(Y^2) = \frac{1}{n}\sum y_i^2$, usando $\mathrm{E}(Y^2) = \mathrm{V}(Y) + [\mathrm{E}(Y)]^2$.
3. Despeja y ponle gorro al parámetro.

Ejemplos de clase (2 sep)

- $U(0,\theta)$: $\mathrm{E}(Y) = \theta/2 = \bar{y} \Rightarrow \hat{\theta} = 2\bar{y}$.
- Gamma(α,β): $\alpha\beta = \bar{y}$ y $\alpha\beta^2 + \alpha^2\beta^2 = \frac{1}{n}\sum y_i^2$. Despejando, $\hat{\alpha} = \dfrac{n\bar{y}^2}{\sum(y_i-\bar{y})^2}$ y $\hat{\beta} = \dfrac{\sum(y_i-\bar{y})^2}{n\bar{y}}$.
- Si $\mathrm{E}(Y) = \theta + \frac{1}{2}$ (uniforme en $(\theta, \theta+1)$): $\hat{\theta} = \bar{y} - \frac{1}{2}$.

2.7 Máxima verosimilitud (MLE)

La idea es escoger el valor de θ que hace más probable la muestra que de verdad observaste.

Receta: MLE en 5 pasos

1. $L(\theta) = \prod_{i=1}^{n} f(y_i \mid \theta)$.
2. Simplifica el producto, igual que en suficiencia.
3. Saca logaritmo: $\ln L(\theta)$. Los productos se vuelven sumas, $\ln(a^b) = b \ln a$ y $\ln e^x = x$.
4. Deriva respecto a θ e iguala a 0.
5. Despeja $\hat{\theta}$. Si alcanzas, verifica que la segunda derivada sea negativa (es un máximo).

$\frac{d}{d\theta} \ln \theta = \frac{1}{\theta}$	$\frac{d}{d\theta} \frac{1}{\theta} = -\frac{1}{\theta^2}$	$\frac{d}{d\theta} \ln(\theta + 1) = \frac{1}{\theta+1}$	$\frac{d}{d\sigma^2} \ln \sigma^2 = \frac{1}{\sigma^2}$
$\frac{d}{d\sigma^2} \frac{1}{\sigma^2} = -\frac{1}{\sigma^4}$	$\ln \prod y_i = \sum \ln y_i$	$\ln \theta^{-2n} = -2n \ln \theta$	$\frac{d}{dp} \ln(1-p) = -\frac{1}{1-p}$

Bernoulli (cuaderno 2 sep)

$L(p) = p^y (1-p)^{n-y}$ con $y = \sum y_i$. Entonces $\ln L = y \ln p + (n-y) \ln(1-p)$ y $\frac{d}{dp} \ln L = \frac{y}{p} - \frac{n-y}{1-p} = 0$. Despejando: $y(1-\hat{p}) = \hat{p}(n-y)$, luego $y = n\hat{p}$ y $\boxed{\hat{p} = y/n}$.

Normal (cuaderno 2 sep)

$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (y_i - \mu)^2$.

- $\frac{\partial}{\partial \mu} = \frac{1}{\sigma^2} \sum (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}$.
- $\frac{\partial}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (y_i - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum (y_i - \bar{y})^2$. Divide por n, así que es sesgado.

¡Ojo! · MLE cuando el soporte depende de θ: no derives

Para $U(0, \theta)$, $L(\theta) = \theta^{-n}$ si $\theta \geq y_{(n)}$ y 0 si no. Esa función **decrece** en θ, así que se maximiza en el valor más pequeño permitido: $\boxed{\hat{\theta} = Y_{(n)}}$. Derivar e igualar a cero no funciona porque $-n/\theta^{n+1}$ nunca vale 0.

Dos muestras normales con varianza común (tipo Parcial 2024, #4)

Con $X_i \sim N(\mu_1, \sigma^2)$, $i = 1..m$, y $Y_j \sim N(\mu_2, \sigma^2)$, $j = 1..n$, la log-verosimilitud conjunta es la **suma** de las dos log-verosimilitudes. Sale $\hat{\mu}_1 = \bar{x}$, $\hat{\mu}_2 = \bar{y}$ y $\hat{\sigma}^2 = \dfrac{\sum (x_i - \bar{x})^2 + \sum (y_j - \bar{y})^2}{m+n}$. La solución completa está en la Guía de solución.

2.8 Monte Carlo para estudiar estimadores (script `sep18.R`)

Si no quieres o no puedes hacer la cuenta teórica, puedes **simular**. Fijas una población con θ conocido, generas miles de muestras, calculas $\hat{\theta}$ en cada una y miras:

$$\widehat{\text{Sesgo}} = \frac{1}{B}\sum \hat{\theta}_b - \theta, \qquad \widehat{\text{V}} = \text{var}(\hat{\theta}_b), \qquad \widehat{\text{ECM}} = \frac{1}{B}\sum (\hat{\theta}_b - \theta)^2.$$

```
evaluar_estimadores = function(n, mu, sigma, n.sim){
  medias = numeric(n.sim); medianas = numeric(n.sim)
  for(i in 1:n.sim){
    x = rnorm(n, mean = mu, sd = sigma)
    medias[i] = mean(x); medianas[i] = median(x)
  }
  data.frame(Estimador = c("Media", "Mediana"),
             Sesgo    = c(mean(medias) - mu, mean(medianas) - mu),
             Varianza = c(var(medias), var(medianas)),
             ECM      = c(mean((medias - mu)^2), mean((medianas - mu)^2)))
}
set.seed(123); evaluar_estimadores(n = 15, mu = 10, sigma = 2, n.sim = 100000)
```

Ambos salen prácticamente insesgados, pero la mediana tiene mayor varianza y mayor ECM. La media es más eficiente, lo mismo que dice el 0.6366 de la teoría.

2.9 Autoevaluación del Bloque 1

Responde sin mirar y luego verifica

1. Si $\text{E}(\hat{\theta}) = \theta + 2$, ¿cuál es el sesgo y cuál es el estimador insesgado? *(2; $\hat{\theta} - 2$)*
2. ¿ECM es mayor, menor o igual que V para un estimador sesgado? *(mayor)*
3. $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = 1.4$. ¿Con cuál te quedas? *(con $\hat{\theta}_1$)*
4. ¿Cuál es el MLE de θ en $U(0, \theta)$? ¿Y el de momentos? *($Y_{(n)}$; $2\bar{Y}$)*
5. ¿Qué dos cosas debes mostrar para la consistencia según la profe? *(insesgado y $\text{V} \to 0$)*
6. En la factorización, ¿qué no puede tener h? *(θ)*

3 Intervalos (Bloque 2)

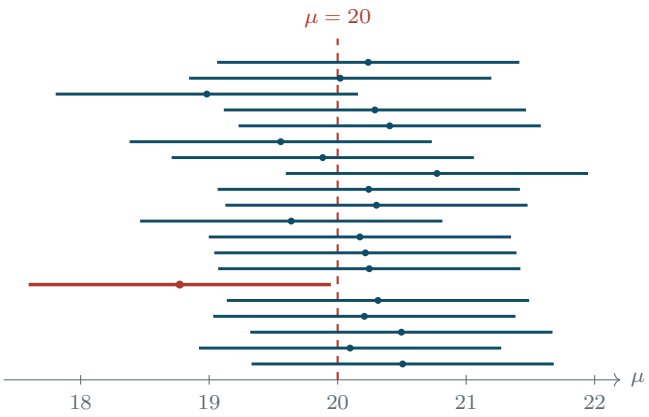
3.1 La idea de un intervalo de confianza

Un estimador puntual ($\bar{x} = 51.5$) casi nunca es exactamente el parámetro. Un **intervalo de confianza** (IC) da un rango de valores plausibles y una medida de qué tan confiable es el procedimiento.

Qué significa "95% de confianza"

El parámetro μ es fijo. Lo que cambia de muestra a muestra es el intervalo. Si repites el muestreo muchas veces y en cada muestra construyes el IC del 95%, **aproximadamente el 95% de esos intervalos atrapan a** μ. La figura muestra 20 intervalos simulados con $\mu = 20$ ($n = 25$, $\sigma = 3$);

uno de ellos, el rojo, no lo atrapa.



Cómo lo redacta la profe

"Con un nivel de confianza del 95%, *[el parámetro en contexto, con unidades]* está entre *LI* y *LS*." Ejemplo (cuaderno 14 sep): "Con un nivel de confianza de 99% el tiempo medio requerido para completar la capacitación está entre 47.12 y 55.88 minutos".

¡Ojo! · No digas "hay 95% de probabilidad de que μ esté entre 47.12 y 55.88"

Una vez calculado, el intervalo contiene a μ o no lo contiene, y no hay probabilidad de por medio. El 95% describe al *método*, no a un intervalo particular. En un V/F esa frase es falsa.

3.2 Anatomía de un IC (notación de la profe)

$$\underbrace{\hat{\theta}}_{\text{e.p.}} \pm \underbrace{(\text{valor crítico}) \times \text{SE}(\hat{\theta})}_{\text{m.e.}} \quad \Longrightarrow \quad \text{L.I.} = \text{e.p.} - \text{m.e.}, \qquad \text{L.S.} = \text{e.p.} + \text{m.e.}$$

e.p. es la estimación puntual y m.e. el margen de error. El ancho del intervalo es $2 \times$ m.e.. El intervalo se vuelve **más ancho** con:

- **Más confianza** (99% es más ancho que 95%, que es más ancho que 90%). Cuaderno 4 sep: 90% $(245.57, 261.33)$, 95% $(244.03, 262.87)$, 99% $(240.99, 265.91)$.
- **Más variabilidad** (σ o s grandes).
- **Menos datos** (n pequeño). Para reducir el ancho a la mitad hay que multiplicar n por 4.

3.3 Método del pivote (de dónde salen las fórmulas)

Un **pivote** es una cantidad que (1) depende de los datos y del parámetro θ, con θ como única incógnita, y (2) tiene una distribución que **no** depende de θ. Se encierra el pivote entre dos cuantiles y se despeja θ.

Pivote clásico: la media con σ conocida

$P\left(-z_{\alpha/2} \le \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \le z_{\alpha/2}\right) = 1-\alpha$. Despejando μ queda $P\left(\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \mu \le \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1-\alpha$.

Pivotes "raros" de las diapositivas (pueden salir en la parte teórica)

- **Una observación exponencial con media θ.** $U = Y/\theta \sim \text{Exp}(1)$ y $P(U > u) = e^{-u}$. Para 90% buscas a, b con $P(U < a) = 0.05$ y $P(U > b) = 0.05$: $a = -\ln 0.95 = 0.0513$ y $b = -\ln 0.05 = 2.996$. Entonces $a \le Y/\theta \le b \iff \dfrac{Y}{2.996} \le \theta \le \dfrac{Y}{0.0513}$.
- Con $2Y/\theta \sim \chi^2_2$ sale lo mismo: χ^2_2 tiene cuantiles 0.1026 y 5.991, y $\dfrac{2Y}{5.991} \le \theta \le \dfrac{2Y}{0.1026}$.
- **Una observación de $U(0,\theta)$, límite inferior del 95%.** $Y/\theta \sim U(0,1)$ y $P(Y/\theta \le 0.95) = 0.95$. Así $\theta \ge Y/0.95$, y el límite inferior es $Y/0.95$.

3.4 ¿Qué fórmula uso? Árbol de decisión

Pregúntate en este orden

1. **¿Qué parámetro?** Media μ, proporción p, varianza σ^2, o comparación de dos: $\mu_1 - \mu_2$, $p_1 - p_2$, σ_1^2/σ_2^2. *Pista:* si los datos son 0/1, sí/no o conteos de éxitos, es proporción. Si son medidas (tiempos, pesos, puntajes), es media.
2. **¿Una o dos poblaciones?** Si son dos, **¿pareadas o independientes?** Son *pareadas* si cada dato de un grupo tiene "pareja" natural en el otro: mismo paciente antes/después, mismo atleta en dos rutinas, mismo auto con dos llantas, mismo oído izquierdo/derecho de la misma persona.
3. **Para medias:** ¿conoces σ (dato poblacional, "estudios anteriores indican que la desviación *poblacional* es…")? Entonces usa z. Si solo tienes s de la muestra, usa t.
4. **Para dos medias independientes con σ desconocidas:** ¿varianzas iguales? Si el enunciado lo dice, hazle caso. Si no lo dice, haz primero el IC del cociente con `var.test`: si **contiene 1**, usa varianzas iguales (pooled); si no, usa Welch. La nota de la profe es que en la vida real se asumen desconocidas y diferentes.

Caso	Intervalo	En R
μ, σ conocida	$\bar{x} \pm z_{\alpha/2}\dfrac{\sigma}{\sqrt{n}}$	manual con `qnorm`
μ, σ desconocida (pobl. normal)	$\bar{x} \pm t_{\alpha/2;\,n-1}\dfrac{s}{\sqrt{n}}$	`t.test(x, conf.level=)`
p	$\hat{p} \pm z_{\alpha/2}\sqrt{\dfrac{\hat{p}\hat{q}}{n}} \quad (n\hat{p}, n\hat{q} \geq 5)$	manual, o `prop.test(x, n, conf.level=, correct=FALSE)`
σ^2 (pobl. normal)	$\dfrac{(n-1)s^2}{\chi^2_{\text{grande}}} \leq \sigma^2 \leq \dfrac{(n-1)s^2}{\chi^2_{\text{pequeño}}}$	`qchisq(1-a/2, n-1)` (grande), `qchisq(a/2, n-1)` (pequeño)
$\mu_1 - \mu_2$, σ's conocidas	$(\bar{x}_1 - \bar{x}_2) \pm z_{\alpha/2}\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}$	manual con `qnorm`
$\mu_1 - \mu_2$, iguales (pooled)	$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2;\,n_1+n_2-2}\sqrt{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$	`t.test(x1, x2, var.equal=TRUE)`
$\mu_1 - \mu_2$, diferentes (Welch)	$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2;\,gl}\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}$	`t.test(x1, x2)` (Welch es el default)
μ_D pareadas	$\bar{d} \pm t_{\alpha/2;\,n-1}\dfrac{s_d}{\sqrt{n}}$	`t.test(x1, x2, paired=TRUE)`
$p_1 - p_2$	$(\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2}\sqrt{\dfrac{\hat{p}_1\hat{q}_1}{n_1} + \dfrac{\hat{p}_2\hat{q}_2}{n_2}}$	`prop.test(c(x1,x2), c(n1,n2), correct=FALSE)`
σ_1^2/σ_2^2 (normales)	$\dfrac{s_1^2}{s_2^2}\dfrac{1}{F_{1-\alpha/2;\,gl_1,gl_2}} \leq \dfrac{\sigma_1^2}{\sigma_2^2} \leq \dfrac{s_1^2}{s_2^2}F_{1-\alpha/2;\,gl_2,gl_1}$	`var.test(x1, x2, conf.level=)`

Con $s_p^2 = \dfrac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}$, $gl_{\text{Welch}} = \dfrac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$, $gl_1 = n_1 - 1$, $gl_2 = n_2 - 1$. Las gl de Welch casi nunca son enteras (7.19, 47.8…) y eso es normal.

3.5 Una población, caso por caso

3.5.1 Media con σ conocida (z)

```
n = 49; sigma = 5; promedio = 24.8; nc = 0.95; alpha = 1 - nc
se = sigma/sqrt(n)                      # error estándar
z  = qnorm(alpha/2, lower.tail = FALSE)  # 1.96
me = z*se                               # margen de error
LI = promedio - me; LS = promedio + me  # 23.40 y 26.20
```

3.5.2 Media con σ desconocida (t)

Supuesto: la población es normal. Se verifica con un histograma, o con n grande gracias al TLC.

```
tiempos = c(52,59,54,42,44,50,42,48,55,54,60,55,44,62,62,57,45,46,43,56)
t.test(tiempos, conf.level = 0.99)       # IC: 47.12 a 55.88
```

```r
# a mano, como en clase_sep14.R
n = length(tiempos); se = sd(tiempos)/sqrt(n)
t = abs(qt(0.01/2, n-1))                # 2.861
mean(tiempos) - t*se; mean(tiempos) + t*se
```

3.5.3 Proporción

```r
n = 2000; x = 1600; nc = 0.95; alpha = 1 - nc
pe = x/n; qe = 1 - pe; se = sqrt(pe*qe/n)
z = qnorm(alpha/2, lower.tail = FALSE)
pe - z*se; pe + z*se                    # 0.782 a 0.818 (fórmula de clase)
prop.test(x, n, conf.level = 0.95, correct = FALSE)   # 0.7819 a 0.8169
```

¡Ojo! · prop.test de UNA muestra no da exactamente la fórmula

Para una sola proporción, `prop.test` usa otro método (Wilson) y el IC cambia en el tercer decimal. Si te piden "a mano", usa la fórmula. Si piden R, cualquiera de los dos sirve, pero di cuál usaste. Para **dos** proporciones, `prop.test(..., correct=FALSE)` da *exactamente* la fórmula de clase.

3.5.4 Varianza y desviación estándar

Supuesto: población normal, y este intervalo es muy sensible a que se cumpla.

```r
pesos = c(46.4,46.1,45.8,47.0,46.1,45.9,45.8,46.9,45.2,46.0)
n = length(pesos); s2 = var(pesos); alpha = 0.05
LI = (n-1)*s2/qchisq(1 - alpha/2, n-1)   # 0.1354  (se divide por el chi GRANDE)
LS = (n-1)*s2/qchisq(alpha/2, n-1)       # 0.9539  (se divide por el chi PEQUEÑO)
sqrt(c(LI, LS))                           # IC para sigma: 0.368 a 0.977
```

¡Ojo! · El IC de la varianza no es simétrico

$s^2 = 0.286$ no queda en el centro de $(0.135, 0.954)$, y eso está bien porque la χ^2 es asimétrica. Para σ se saca la raíz a los dos límites; **no** se calcula otro intervalo.

3.6 Dos poblaciones, caso por caso

3.6.1 Cómo leer un IC de diferencia (cuaderno 11 sep)

Si el IC para $\mu_1 - \mu_2$ (o $p_1 - p_2$)…	Conclusión
contiene al 0 (LI negativo y LS positivo)	$\mu_1 \approx \mu_2$: no hay diferencia significativa
tiene ambos límites positivos	$\mu_1 > \mu_2$
tiene ambos límites negativos	$\mu_1 < \mu_2$

3.6.2 Medias con σ_1, σ_2 conocidas

```
n1 = 40; n2 = 35; prom1 = 2.04; prom2 = 1.72; sigma1 = 0.10; sigma2 = 0.08
ep = prom1 - prom2; nc = 0.90; a = 1 - nc
z = qnorm(a/2, lower.tail = FALSE); se = sqrt(sigma1^2/n1 + sigma2^2/n2)
me = z*se; ep - me; ep + me              # 0.286 a 0.354: ambos +, California > Florida
```

3.6.3 Medias con varianzas desconocidas: primero el cociente

```
est = c(32,37,35,28,41,44,35,31,34); nue = c(35,31,29,25,34,40,27,32,31)
var.test(est, nue, conf.level = 0.95)    # IC cociente: 0.275 a 5.411 -> contiene 1
t.test(est, nue, conf.level = 0.95, var.equal = TRUE)   # df = 16; IC -1.046 a 8.379
```

Cómo leer el IC del cociente de varianzas

Contiene al 1: "las varianzas son aproximadamente iguales". Ambos límites mayores que 1: $\sigma_1^2 > \sigma_2^2$ (la población 1 es más variable). Ambos menores que 1: $\sigma_1^2 < \sigma_2^2$.

Si las varianzas son diferentes, usa Welch, que es lo que hace `t.test` por defecto:

```
e1 = c(103,94,110,87,98); e2 = c(97,82,123,92,175,88,118)
t.test(e1, e2, conf.level = 0.90)        # df = 7.19; IC -36.43 a 11.80 -> contiene 0
```

3.6.4 Pareadas

```
A = c(10.6,9.8,12.3,9.7,8.8); B = c(10.2,9.4,11.8,9.1,8.3)
d = A - B                                # 0.4 0.4 0.5 0.6 0.5
t.test(A, B, paired = TRUE)              # IC 95%: 0.376 a 0.584 -> ambos +, A se desgasta más
```

¿Por qué parear?

Si cada auto (o persona) aparece en los dos grupos, las diferencias entre autos son ruido. Al restar dentro de cada par, ese ruido desaparece y queda solo el efecto del tratamiento. Por eso el IC pareado es mucho más angosto. Tratar datos pareados como independientes está **mal**: viola la independencia entre las muestras.

3.6.5 Diferencia de proporciones

```
x1 = 12; n1 = 50; x2 = 12; n2 = 60
prop.test(c(x1,x2), c(n1,n2), conf.level = 0.98, correct = FALSE)   # -0.145 a 0.225
```

3.6.6 Cociente de varianzas cuando solo te dan s_1, s_2

`var.test` necesita los datos. Con solo resúmenes tienes dos caminos:

```
# (1) Fórmula con qf (código de la guía de IC de la profe)
nA = 11; sA = 2.4; nB = 13; sB = 1.1; alpha = 0.10
coc = sA^2/sB^2
coc/qf(1-alpha/2, nA-1, nB-1);  coc*qf(1-alpha/2, nB-1, nA-1)        # 1.729 a 13.867
# (2) Solo funciones de clase: datos "sintéticos" con la s EXACTA
xa = rnorm(nA); xa = (xa - mean(xa))/sd(xa)*sA
xb = rnorm(nB); xb = (xb - mean(xb))/sd(xb)*sB
var.test(xa, xb, conf.level = 0.90)        # da exactamente el mismo IC
```

El truco (2) funciona porque `var.test` solo usa n_1, n_2, s_1^2, s_2^2, y al estandarizar s queda idéntica a la del enunciado. Con medias y desviaciones ($\bar{x}$ y s) sirve igual para `t.test`: `x = (x-mean(x))/sd(x)*s + xbarra`.

3.7 Problemas "al revés" (muy del Externado)

Del intervalo puedes recuperar los ingredientes:

$$\text{e.p.} = \frac{LI + LS}{2}, \qquad \text{m.e.} = \frac{LS - LI}{2}, \qquad s = \frac{\text{m.e.}\sqrt{n}}{t_{\alpha/2;\,n-1}}, \qquad n = \left(\frac{z_{\alpha/2}\,\sigma}{\text{m.e.}}\right)^2.$$

Cuaderno 4 sep: deducir s de la salida de R

Con IC del 95% (0.988, 2.612), $\bar{x} = 1.8$ y $n = 10$: m.e. $= 1.8 - 0.988 = 0.812$ y $t_{0.025;9} =$ `abs(qt(0.025,9))` $= 2.262$. Entonces $2.262 \cdot s/\sqrt{10} = 0.812$, y $s = 0.812\sqrt{10}/2.262 = 1.135$.

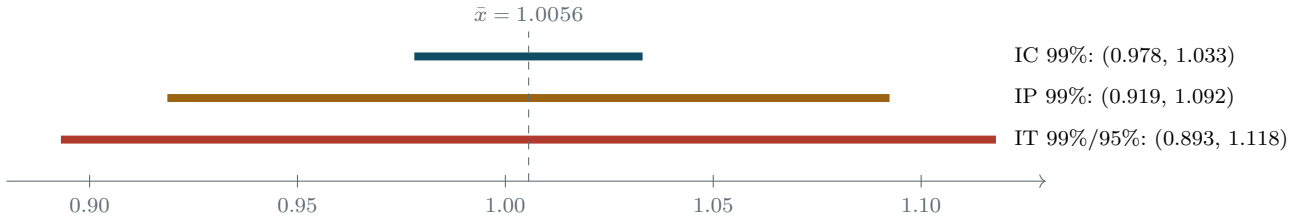
Tamaño de muestra. Para un margen de error E: $n = \left(\frac{z\sigma}{E}\right)^2$ para medias y $n = \frac{z^2\,p(1-p)}{E^2}$ para proporciones (usa $p = 0.5$ si no sabes nada, que es el peor caso). **Siempre redondea hacia arriba.**

3.8 Intervalo de predicción y límites de tolerancia

Son tres preguntas distintas sobre la misma muestra:

Intervalo	Pregunta que responde	Fórmula	Interpretación (estilo profe)
Confianza (IC)	¿Dónde está la **media** μ de la población?	$\bar{x} \pm t\,\frac{s}{\sqrt{n}}$	"Con 99% de confianza el diámetro *medio* está entre…"
Predicción (IP)	¿Dónde caerá **la próxima** observación x_0?	$\bar{x} \pm t\,s\sqrt{1 + \frac{1}{n}}$	"La *próxima* pieza tendrá un diámetro entre…"
Tolerancia (IT)	¿Entre qué valores está **al menos el P% de toda la población**?	$\bar{x} \pm k\,s$	"Con 99% de confianza, *al menos el 95% de las piezas* tiene diámetro entre…"

Si σ es conocida, el IP es $\bar{x} \pm z_{\alpha/2}\,\sigma\sqrt{1+1/n}$. El IP es más ancho que el IC porque suma dos incertidumbres: no sabemos μ (el "$1/n$") y además una observación individual varía alrededor de μ (el "1"). Por eso, aunque $n \to \infty$, el IP no se encoge a cero.



Ejemplo de la máquina (9 diámetros, diapositiva de predicción): IC < IP < IT.

Límites unilaterales. Para el extremo superior se usa un solo lado y el crítico deja α (no $\alpha/2$) en la cola: límite superior de predicción $\bar{x} + t_{\alpha;\,n-1}\,s\sqrt{1+1/n}$, y límite superior de tolerancia $\bar{x} + k_1 s$ (con `side = 1`). Así es el ejercicio del ortofósforo del preparcial.

```r
library(tolerance)
diam = c(1.01,0.97,1.03,1.04,0.99,0.98,0.99,1.01,1.03)
# Predicción (a mano, como en IC_tolerancia_y_Boostrap.R)
n = length(diam); t = abs(qt(0.01/2, n-1))
mean(diam) - t*sd(diam)*sqrt(1+1/n); mean(diam) + t*sd(diam)*sqrt(1+1/n)
# Tolerancia: alpha = 1 - CONFIANZA ; P = PROPORCIÓN de la población
normtol.int(x = diam, alpha = 0.01, P = 0.95, side = 2, method = "EXACT")
```

¡Ojo! · normtol.int: tres errores que salen caros

1. `alpha` es 1−**confianza** (0.01 para 99%) y `P` es la **proporción** de población que quieres cubrir (0.95). No los cruces.
2. Si te dan los datos, pásale **los datos**. En clase se simularon datos con `rnorm(n, mean=, sd=)` y eso da un resultado distinto cada vez (por eso salió 0.886–1.115 y no 0.893–1.118). Si solo te dan $\bar{x}$, s y n, usa datos sintéticos con media y s **exactas**: `x = rnorm(n); x = (x-mean(x))/sd(x)*s + xbarra`. Así `normtol.int` da el resultado exacto $\bar{x} \pm ks$.
3. El k de la tabla del libro (2.140) y el exacto de R (2.145) difieren un poco. Cualquiera es válido si dices de dónde salió.

3.9 Bootstrap: intervalos sin suponer normalidad

La idea en una frase

Como no podemos sacar más muestras de la población, tratamos la muestra como si fuera la población y **remuestreamos con reemplazo** B veces. La dispersión de las estimaciones $\hat{\theta}^*$ imita la dispersión real de $\hat{\theta}$. "El bootstrap no crea información nueva, extrae la información de variabilidad que ya está contenida en la muestra."

Algoritmo

1. Calcula $\hat{\theta}$ (por ejemplo $\bar{x}$) en la muestra original.
2. Repite B veces (1000, 2000, 10000): toma una muestra de tamaño n **con reemplazo** de los datos y calcula $\hat{\theta}^*_b$.
3. SE_{boot} = desviación estándar de los $\hat{\theta}^*_b$.
4. IC percentil del 95%: los percentiles 2.5% y 97.5% de los $\hat{\theta}^*_b$.

```
x = c(...)                                    # tus datos
set.seed(1504)
medias_boot = replicate(10000, mean(sample(x, size = length(x), replace = TRUE)))
mean(medias_boot); se_boot = sd(medias_boot); se_boot     # SE bootstrap
hist(medias_boot, probability = TRUE, col = "lightblue", border = "white")
lines(density(medias_boot), col = "blue", lwd = 2)
# IC percentil con el paquete boot (IC_tolerancia_y_Boostrap.R)
library(boot)
boot_promedio = function(datos, indices){ return(mean(datos[indices])) }
boots = boot(x, statistic = boot_promedio, R = 10000)
boot.ci(boots, type = "perc", conf = 0.95)
# Intervalo "normal": media +/- 2 SE
mean(x) - 2*se_boot; mean(x) + 2*se_boot
```

Si el histograma bootstrap es simétrico y en forma de campana, el IC percentil y $\bar{x} \pm 2\,\text{SE}_{boot}$ dan casi lo mismo. Con `Pulse` de BodyTemp50 salen (72.6, 76.1) y (72.6, 76.2).

	IC clásico (t)	**IC bootstrap**
Supuestos	Normalidad o n grande	Solo independencia (que la muestra represente a la población)
Cálculo	Fórmula cerrada	Simulación (remuestreo)
Ventaja	Rápido y exacto si se cumple el supuesto	Sirve para medianas, cuantiles y datos asimétricos
Desventaja	Sensible a atípicos y a la falta de normalidad	Costo computacional; impreciso con n muy pequeño

¡Ojo! · V/F típicos de bootstrap

El remuestreo es **con** reemplazo (no "sin"). Cada muestra bootstrap contiene en promedio el 63.2% de los datos distintos (el 36.8% queda "fuera de la bolsa"). El bootstrap **no** corrige una muestra sesgada o no representativa. La media de la distribución bootstrap se centra en $\bar{x}$, no en μ.

3.10 Monte Carlo: ¿el intervalo cumple lo que promete?

En Monte Carlo **tú inventas la población** y por eso conoces el parámetro verdadero. Generas muchas muestras, construyes el IC en cada una y cuentas qué proporción de intervalos contiene al parámetro. Esa es la **cobertura empírica**. Si el método es bueno, sale cerca del nivel nominal (0.95).

	Monte Carlo	**Bootstrap**
Datos	Generados de una distribución teórica conocida	La muestra observada
Mecanismo	Números aleatorios (`rnorm`, `rbinom`)	Remuestreo con reemplazo (`sample`)
Responde	¿Cómo se comporta el método en teoría?	¿Qué inferencia hago con estos datos reales?

Plantilla (es la función `ic_m_C1` de `sep18.R`). Para cada variante solo cambian las líneas marcadas:

```
ic_m_C1 = function(n, mu, sigma, n.sim, n.c){
  li = c(); ls = c()
  for(i in 1:n.sim){
    x = rnorm(n, mu, sigma)                                  # <- cómo se generan los datos
    li[i] = mean(x) - qnorm((1-n.c)/2, lower.tail=FALSE)*(sigma/sqrt(n))   # <- e.p. - m.e.
    ls[i] = mean(x) + qnorm((1-n.c)/2, lower.tail=FALSE)*(sigma/sqrt(n))   # <- e.p. + m.e.
  }
  mean(ifelse(li < mu & mu < ls, 1, 0))                      # <- parámetro verdadero
}
ic_m_C1(n = 25, mu = 20, sigma = 3, n.sim = 10000, n.c = 0.95)
```

- t **(σ desconocida):** usa `s = sd(x)` y `qt((1-n.c)/2, n-1, lower.tail=FALSE)*(s/sqrt(n))`. Es `ic_m_C2` del script.
- **Dos medias:** genera dos muestras, `x1 = rnorm(n1, mu1, s1)` y `x2 = rnorm(n2, mu2, s2)`. La e.p. es `mean(x1) - mean(x2)` y el parámetro verdadero es `mu1 - mu2`. Con pooled: `sp2 = ((n1-1)*var(x1)+(n2-1)*var(x2))/(n1+n2-2)`.
- **Proporción:** `x = rbinom(1, n, p); ph = x/n`; SE `sqrt(ph*(1-ph)/n)`; parámetro `p`.

Lo que se observa en los preparciales: z de dos medias ≈ 0.953, pooled ≈ 0.951, Wald para $p \approx 0.947$ (se queda un poco corto) y diferencia de proporciones ≈ 0.950. Al subir n, la cobertura sigue cerca de 0.95, pero los intervalos se **angostan** ($\propto 1/\sqrt{n}$): con $n = 15, 30, 50$ por grupo la amplitud media pasa de 5.94 a 4.12 y a 3.17.

3.11 Autoevaluación del Bloque 2

Responde sin mirar

1. IC 95% para $\mu_1 - \mu_2$: $(-3.1, -1.0)$. ¿Qué concluyes? *($\mu_1 < \mu_2$)*
2. IC del cociente (2.2, 174.7). ¿Varianzas iguales? *(no; $\sigma_1^2 > \sigma_2^2$)*
3. ¿Cuál es más ancho: IC, IP o IT? *($IT > IP > IC$)*

4. ¿Con qué χ^2 se divide para el límite inferior de σ^2? *(el grande)*
5. 10 pacientes medidos antes y después: ¿independientes o pareadas? *(pareadas)*
6. En `normtol.int`, ¿qué es `alpha`? *(1 − confianza)*

4 Pruebas de hipótesis (Bloque 3)

4.1 La idea: un juicio

Una prueba de hipótesis funciona como un juicio. El acusado es *inocente hasta que se demuestre lo contrario*:

- H_0, la **hipótesis nula**, es "la que siempre ha sucedido y se supone verdadera hasta que se demuestre lo contrario" (definición de la profe). Es el inocente.
- H_1, la **hipótesis alterna**, es "la que propone el investigador". Es lo que el fiscal quiere probar.
- Los datos son la evidencia. Solo si la evidencia es muy fuerte contra H_0 la rechazamos.

¡Ojo! · No rechazar NO es demostrar H_0

Si no rechazas H_0, la frase correcta es "los datos **no dan evidencia** de H_1". Nunca digas "se demostró H_0" ni "se acepta H_0 como verdadera". Un acusado absuelto por falta de pruebas no queda demostrado inocente. Esto sale en preguntas como "¿existe evidencia de que la afirmación del señor Martínez es válida?".

4.2 Plantear las hipótesis a partir del texto

Regla de oro: el signo igual ($=$, $\leq$, $\geq$) siempre va en H_0. La cola de la prueba la define el signo de H_1.

Si el enunciado dice...	H_0	H_1	Tipo
"mayor que", "aumentó", "excede", "más de", "supera"	$\theta \leq \theta_0$	$\theta > \theta_0$	cola derecha
"menor que", "disminuyó", "redujo", "menos de"	$\theta \geq \theta_0$	$\theta < \theta_0$	cola izquierda
"cambió", "es diferente", "hay diferencia", "se mantiene igual / es igual"	$\theta = \theta_0$	$\theta \neq \theta_0$	dos colas
"al menos", "no menos de" (la afirmación tiene $\geq$)	$\theta \geq \theta_0$	$\theta < \theta_0$	cola izquierda
"a lo sumo", "no más de" (la afirmación tiene $\leq$)	$\theta \leq \theta_0$	$\theta > \theta_0$	cola derecha

Los incisos del ejercicio 5 de la guía de PH

"A lo sumo 20% se exportará": $H_0 : p \leq 0.20$, $H_1 : p > 0.20$, región crítica a la derecha. "En promedio beben 3 tazas": $H_0 : \mu = 3$, $H_1 : \mu \neq 3$, dos colas. "Al menos 0.15": $H_0 : p \geq 0.15$, $H_1 : p < 0.15$, izquierda. "No mayor de 10 dólares": $H_0 : \mu \leq 10$, $H_1 : \mu > 10$, derecha.

¡Ojo! · La diferencia hipotética no siempre es 0

"El promedio de edad de las mujeres **excede en 6 años** al de los hombres" se escribe $H_0 : \mu_M - \mu_H \leq 6$ contra $H_1 : \mu_M - \mu_H > 6$. En R va como `mu = 6` dentro de `t.test`. Lo mismo en la salida de Carseats: "*true difference in means is less than 0.5*" significa $H_1 : \mu_1 - \mu_2 < 0.5$.

4.3 Los 5 pasos de la profe

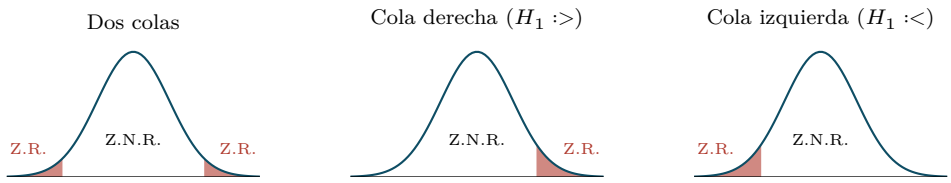
Siempre en este orden (cuadernos del 21 y 23 sep)

1. **Plantear las hipótesis** H_0 y H_1 y decir qué tipo de prueba es (dos colas, cola derecha o cola izquierda). Define la variable: "$X :=$ saldo de las cuentas de…".
2. **Nivel de significancia** α.
3. **Estadístico de prueba**, calculado con los datos y el valor hipotético de H_0: z_c, t_c, χ^2_c o F_c.
4. **Regla de decisión**, por el método del punto crítico, por el del p-valor, o por los dos si lo piden.
5. **Conclusión en contexto.**

4.3.1 Regla de decisión: punto crítico y p-valor

Prueba	Punto crítico: rechazo H_0 si...	p-valor (con t; con z cambia `pt` por `pnorm`)
Dos colas	$t_c < -t_{\alpha/2;gl}$ o $t_c > t_{\alpha/2;gl}$ crítico: `abs(qt(alpha/2, gl))`	$P(\lvert t\rvert > \lvert t_c\rvert)$ = `pt(-abs(tc), gl) + pt(abs(tc), gl, lower.tail=FALSE)`
Cola derecha	$t_c > t_{\alpha;gl}$ crítico: `qt(alpha, gl, lower.tail=FALSE)`	$P(t > t_c)$ = `pt(tc, gl, lower.tail=FALSE)`
Cola izquierda	$t_c < -t_{\alpha;gl}$ crítico: `qt(alpha, gl)` (sale negativo)	$P(t < t_c)$ = `pt(tc, gl)`

Regla del p-valor: si p-valor $< \alpha$, se rechaza H_0. Los dos métodos siempre llevan a la misma decisión.



La zona de rechazo (Z.R.) siempre queda del lado hacia donde apunta H_1.

Conclusión (cuadernos 23 y 28 sep)

Si se rechaza: "Con un nivel de significancia de α, se rechaza la hipótesis nula; por tanto, los

datos dan evidencia de que *[H_1 en palabras del problema]*."
Si no se rechaza: "Con un nivel de significancia de α, no se rechaza la hipótesis nula; por tanto, los datos **no** dan evidencia de que *[H_1 en palabras]*."

Cuaderno 23 sep: calificaciones, ¿la media es menor a 80?

$H_0 : \mu \geq 80$ vs. $H_1 : \mu < 80$ (cola izquierda), $\alpha = 0.05$, $n = 20$. Resultados: $t_c = -1.4925$ y crítico `qt(0.05,19)`$= -1.729$. Como $t_c = -1.49 > -1.729$, cae en la Z.N.R. El p-valor es `pt(-1.4925,19)`$= 0.076 > 0.05$. No se rechaza H_0: los datos no dan evidencia de que las calificaciones medias sean menores a 80 puntos.

4.4 Errores tipo I y II, potencia

	H_0 verdadera	H_0 falsa
No rechazar H_0	Decisión correcta $(1-\alpha)$	**Error tipo II** (β)
Rechazar H_0	**Error tipo I** (α)	Decisión correcta: **potencia** $(1-\beta)$

Cómo redactar los errores en contexto (cuaderno 21 sep)

Con $H_1 : \mu > 56.2$ minutos de TV:
Error tipo I: concluir que los alemanes ven más de 56.2 minutos cuando en realidad *no* es así (H_0 era cierta).
Error tipo II: concluir que no ven más de 56.2 minutos cuando en realidad *sí* ven más (H_0 era falsa).

Qué mueve a qué

- Bajar α de 0.05 a 0.01 reduce la probabilidad de error tipo I, pero (con el mismo n) aumenta β y baja la potencia.
- La potencia **sube** con un n más grande, con un efecto real más grande, con menos variabilidad y con un α más grande.
- "Potencia del 80%" significa que, si en el mundo real existe el efecto, el estudio tiene 80% de probabilidad de detectarlo con un resultado significativo (cuaderno 2 oct).

4.5 El p-valor, sin enredos

Definición: el p-valor es la probabilidad, *suponiendo que H_0 es verdadera*, de obtener un estadístico tan extremo o más que el observado. Equivale al α más pequeño con el que se rechazaría H_0. Entre más pequeño, más evidencia hay contra H_0.

¡Ojo! · V/F que siempre aparecen

- "El p-valor es la probabilidad de que H_0 sea verdadera" es **falso**. Se calcula *suponiendo* H_0 cierta; no es la probabilidad de H_0.

- "p = 0.03 significa 97% de probabilidad de que H_1 sea verdadera" es **falso**.
- "Si p $< \alpha$ se rechaza H_0" es **verdadero**.
- "El tamaño del efecto mide si el resultado es significativo" es **falso**: mide la *magnitud*. La significancia la da el p-valor.
- "Dos estudios pueden tener el mismo p-valor y distinto tamaño del efecto" es **verdadero**, porque el p-valor depende de n.

4.6 Catálogo de pruebas (con la tabla de fórmulas de la profe)

Parámetro	Estadístico de prueba	En R
μ, σ conocida	$z_c = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	manual; p con `pnorm`
μ, σ desconocida	$t_c = \dfrac{\bar{x} - \mu_0}{s/\sqrt{n}}$, $gl = n-1$	`t.test(x, mu=mu0, alternative="less")`
p	$z_c = \dfrac{\hat{p} - p_0}{\sqrt{p_0 q_0/n}}$	`prop.test(x, n, p=p0, alternative=, correct=FALSE)`
$\mu_1 - \mu_2$, σ's conocidas	$z_c = \dfrac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	manual con `pnorm`
$\mu_1 - \mu_2$, iguales	$t_c = \dfrac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{s_p^2(1/n_1 + 1/n_2)}}$, $gl = n_1 + n_2 - 2$	`t.test(x1, x2, mu=d0, alternative=, var.equal=TRUE)`
$\mu_1 - \mu_2$, Welch	$t_c = \dfrac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$, gl de Welch	`t.test(x1, x2, mu=d0, alternative=)`
μ_D pareadas	$t_c = \dfrac{\bar{d} - d_0}{s_d/\sqrt{n}}$, $gl = n-1$	`t.test(x1, x2, paired=TRUE, alternative=)`
$p_1 - p_2$	$z_c = \dfrac{(\hat{p}_1 - \hat{p}_2) - 0}{\sqrt{\hat{p}\hat{q}(1/n_1 + 1/n_2)}}$, $\hat{p} = \dfrac{x_1 + x_2}{n_1 + n_2}$	`prop.test(c(x1,x2), c(n1,n2), alternative=, correct=FALSE)`
σ^2	$\chi_c^2 = \dfrac{(n-1)s^2}{\sigma_0^2}$, $gl = n-1$	manual con `pchisq` / `qchisq`
σ_1^2/σ_2^2	$F_c = s_1^2/s_2^2$, $gl = (n_1 - 1,\, n_2 - 1)$	`var.test(x1, x2, alternative=)`

En `t.test`, `prop.test` y `var.test` el argumento `alternative` va así: `"two.sided"` para $\neq$, `"greater"` para $>$ y `"less"` para $<$.

¡Ojo! · Diferencias sutiles entre IC y prueba para proporciones

1. En la **prueba** de una proporción el SE usa p_0, el de H_0: $\sqrt{p_0 q_0/n}$. En el **intervalo** se usa $\hat{p}$.
2. En la **prueba** de dos proporciones se usa la $\hat{p}$ **agrupada** $(x_1 + x_2)/(n_1 + n_2)$. En el **intervalo** se usan $\hat{p}_1$ y $\hat{p}_2$ por separado.
3. `prop.test` reporta `X-squared`, que es z_c^2. Para recuperar z_c sacas la raíz y le pones el signo de

$\hat{p} - p_0$. Siempre usa `correct = FALSE`, igual que en clase.

Cuaderno 30 sep: sindicatos, ¿aumentó la proporción de 12.5%?

$H_0 : p \leq 0.125$ vs. $H_1 : p > 0.125$, $\alpha = 0.05$, $n = 400$, $x = 52$. Entonces $\hat{p} = 0.13$, SE $= \sqrt{0.125 \cdot 0.875/400} = 0.0165$ y $z_c = 0.302$. El crítico es `qnorm(0.05, lower.tail=FALSE)`$= 1.645$: como $0.302 < 1.645$, no se rechaza. El p-valor es `pnorm(0.302, lower.tail=FALSE)`$= 0.381 > 0.05$. Los datos no dan evidencia de que haya aumentado la proporción de miembros.

```
prop.test(52, 400, p = 0.125, alternative = "greater", correct = FALSE)
```

Cuaderno 28 sep: Welch a mano (28sep.R)

Cherry Grove ($n_1 = 28$, $\bar{x}_1 = 1025$, $s_1 = 150$) vs. Beechmont ($n_2 = 22$, $\bar{x}_2 = 910$, $s_2 = 125$), $\alpha = 0.01$, dos colas.

```
num = (150^2/28 + 125^2/22)^2
den = (150^2/28)^2/(28-1) + (125^2/22)^2/(22-1)
gl = num/den                                    # 47.8
tc = (1025 - 910)/sqrt(150^2/28 + 125^2/22)     # 2.956
qt(0.01/2, gl)                                  # -2.683 -> criticos +/-2.683
pt(-abs(tc), gl) + pt(abs(tc), gl, lower.tail = FALSE)   # p = 0.0048 < 0.01
```

Se rechaza H_0: hay diferencia en los saldos medios de las dos sucursales.

4.6.1 Varianzas

Una varianza (guía de PH, ej. 2.3.1)

Especificación $\sigma^2 \leq 0.0004$. Con $n = 30$ y $s^2 = 0.0005$, $\alpha = 0.05$: $H_0 : \sigma^2 \leq 0.0004$ vs. $H_1 : \sigma^2 > 0.0004$. El estadístico es $\chi^2_c = 29(0.0005)/0.0004 = 36.25$ y el crítico `qchisq(0.95, 29)`$= 42.56$. Como $36.25 < 42.56$, no se rechaza. El p-valor es `pchisq(36.25, 29, lower.tail=FALSE)`$= 0.166$. No hay evidencia de que se viole la especificación.

Cociente (salsa de soya): ¿la línea 1 es menos consistente?

$H_0 : \sigma_1^2 \leq \sigma_2^2$ vs. $H_1 : \sigma_1^2 > \sigma_2^2$. Con `var.test(l1, l2, alternative = "greater")` sale $F = 19.67$ y p $= 0.0004$, así que se rechaza: la línea 1 es más variable.

4.7 Leer salidas de R (aparece seguro)

```
        Two Sample t-test
data:  urbano$Sales and rural$Sales
t = -1.9206, df = 398, p-value = 0.02775
alternative hypothesis: true difference in means is less than 0.5
95 percent confidence interval:
```

```
     -Inf 0.415701
sample estimates:
mean of x mean of y
 7.468191  7.563559
```

Línea	Qué significa
`Two Sample t-test`	Medias independientes con varianzas **iguales** (si fuera Welch diría `Welch Two Sample`).
`t = -1.9206`	Estadístico t_c.
`df = 398`	$gl = n_1 + n_2 - 2$, así que $n_1 + n_2 = 400$.
`p-value = 0.02775`	p-valor de la prueba **de una cola**.
`alternative … less than 0.5`	$H_1 : \mu_1 - \mu_2 < 0.5$ y $H_0 : \mu_1 - \mu_2 \geq 0.5$.
`95 percent … -Inf 0.415701`	IC **unilateral** del 95%: $\mu_1 - \mu_2 \leq 0.4157$.
`mean of x / mean of y`	$\bar{x}_1$ (urbano) y $\bar{x}_2$ (rural).

En `var.test`: `F` $= s_1^2/s_2^2$; `num df` $= n_1 - 1$ y `denom df` $= n_2 - 1$, de donde salen los tamaños de muestra. El IC es para σ_1^2/σ_2^2 y su nivel aparece en la línea "*XX percent confidence interval*"; puede ser 92%, no siempre 95%.

> **¡Ojo! · IC unilateral cuando hay `alternative`**
>
> Si en `t.test` pones `alternative = "less"` o `"greater"`, el IC que imprime es **de una cola** $(-\infty, b)$ o (a, ∞). Si te piden "un IC" bilateral, corre `t.test` sin `alternative`.

4.8 Relación entre IC y prueba

Una prueba de **dos colas** con nivel α rechaza $H_0 : \theta = \theta_0$ exactamente cuando θ_0 queda **fuera** del IC del $(1-\alpha)100\%$. Por eso "el IC contiene 0" equivale a "no hay diferencia significativa". Con una cola, la equivalencia es con el IC unilateral del mismo lado.

4.9 Significancia estadística vs. sustantiva: tamaño del efecto

El p-valor depende mucho de n: con n enorme hasta una diferencia ridícula sale "significativa". Por eso se reporta también la **magnitud** del efecto con la d de Cohen:

$$d = \frac{\bar{x} - \mu_0}{s} \quad \text{(una muestra)}, \qquad d = \frac{\bar{x}_1 - \bar{x}_2}{s_p} \quad \text{(dos muestras)}.$$

Se interpreta con su valor absoluto: $|d| \approx 0.2$ es **pequeño**, 0.5 **mediano** y 0.8 o más **grande**.

```r
library(effsize)
cohen.d(tiempo, NA, mu = 20)     # una muestra: d = (media - mu)/s
```

4.10 Potencia con R

```
power.t.test(n = length(tiempo), delta = abs(mean(tiempo) - mu), sd = sd(tiempo),
             sig.level = 0.05, type = "one.sample", alternative = "one.sided")
```

`type` puede ser `"one.sample"`, `"two.sample"` o `"paired"`, y `alternative` puede ser `"one.sided"` o `"two.sided"`. Con el software del cuaderno del 2 de octubre sale potencia $= 0.886$, así que el estudio tiene 88.6% de probabilidad de detectar un efecto de ese tamaño. En el cuaderno quedó escrito 87.61%, pero R da 0.8861.

> **Para que no te tomen por sorpresa**
>
> Usar la diferencia observada como `delta` da la "potencia observada". Es lo que se hizo en clase y es lo que debes hacer en el parcial. Si el efecto es grande ($|d| > 1.5$), la potencia sale prácticamente 1.

4.11 Bootstrap y permutación en contrastes

Para probar $H_0 : \mu_A = \mu_B$ sin suponer normalidad hay que remuestrear desde un mundo donde H_0 sea cierta. Para eso se **centran** los dos grupos en la media global:

```
media_global = mean(c(grupo_A, grupo_B))
A_transf = grupo_A - mean(grupo_A) + media_global   # ahora A y B tienen la misma media
B_transf = grupo_B - mean(grupo_B) + media_global
diferencia_obs = mean(grupo_A) - mean(grupo_B)
B = 1000
diferencias_boot = replicate(B, {
  mean(sample(A_transf, replace = TRUE)) - mean(sample(B_transf, replace = TRUE)) })
p_bootstrap = mean(abs(diferencias_boot) >= abs(diferencia_obs))   # dos colas
```

El p-valor bootstrap es la proporción de diferencias simuladas (bajo H_0) tan extremas o más que la observada. Se rechaza si $p < \alpha$. Con B grande y datos normales, coincide con el de `t.test`.

4.12 Autoevaluación del Bloque 3

> **Responde sin mirar**
>
> 1. "El nuevo sistema **disminuyó** el consumo promedio de 100 kWh". ¿H_0, H_1 y cola? *($\mu \geq 100$; $\mu < 100$; izquierda)*
> 2. p $= 0.0553$ con $\alpha = 0.01$. ¿Decisión? *(no rechazar)*
> 3. ¿Qué es el error tipo II en palabras? *(no rechazar H_0 siendo falsa)*
> 4. En la prueba de una proporción, ¿el SE lleva $\hat{p}$ o p_0? *(p_0)*
> 5. `X-squared = 3.9876`. ¿Cuánto vale $|z_c|$? *($\sqrt{3.9876} = 1.997$)*
> 6. $d = -0.53$. ¿Cómo es el efecto? *(mediano)*

5 R para el parcial: bases, plantillas y simulacro (Bloque 4)

5.1 Funciones que puedes usar

Para...	Funciones	Dónde aparecen
Probabilidades y cuantiles	`pnorm qnorm pt qt pchisq qchisq pbinom`	scripts (C1, clase05, sep14, ph_sep23, 28sep)
Resúmenes	`mean sd var median length`	todos los scripts
IC y pruebas de medias	`t.test` (`mu`, `alternative`, `conf.level`, `var.equal`, `paired`)	ph_sep23, 28sep, IC_tolerancia
Varianzas	`var.test`	cuaderno 11 sep, guía IC
Proporciones	`prop.test` (`correct=FALSE`)	cuaderno 30 sep, guía IC
Tolerancia	`library(tolerance)`; `normtol.int`	IC_tolerancia (sep 16)
Bootstrap	`replicate`, `sample(..., replace=TRUE)`, `library(boot)`, `boot`, `boot.ci`	script bootstrap, script parcial 1, IC_tolerancia
Efecto y potencia	`library(effsize)`; `cohen.d`; `power.t.test`	prueba_hipotesis_boot (2 oct)
Simulación	`set.seed rnorm rbinom`, `for`, `function`, `ifelse`	sep18, LGN
Gráficos	`hist`, `lines(density())`, `curve(dnorm(...), add=TRUE)`, `abline`	bootstrap

Básicos de manejo de datos (no son "soluciones"): `read.csv`, `names`, `head`, `str`, `nrow`, `sum`, `sqrt`, `abs`, `as.numeric`, `table`, `$`, `[ ]`.

Con alternativa permitida: `qf` (guía de la profe) o el truco de datos sintéticos con `var.test`; `quantile` o `boot.ci`.

5.2 Cargar cada base sin sustos

```
datos = read.csv("insurance.csv")                                  # separador coma
datos = read.csv("icfes_2016.csv", sep = ";", fileEncoding = "latin1")
datos = read.csv("base_depres_espanol_parcial.csv", sep = ";", fileEncoding = "UTF-8-BOM")
datos = read.csv("Audiometry.csv", fileEncoding = "UTF-8-BOM")
names(datos); head(datos); str(datos)        # SIEMPRE revisa nombres y tipos
```

En RStudio también sirve *Import Dataset* (botón del panel Environment): ahí eliges el separador y el encoding con clics.

¡Ojo! · Las trampas que traen las bases del curso

1. **Separador `;`**: icfes, base de depresión, produccion y tecnicas. Si cargas y ves una sola columna gigante, faltó `sep = ";"`.
2. **Tildes dañadas** (`BOGOT\xc1`): falta `fileEncoding = "latin1"`.
3. **BOM** (marca invisible al inicio del archivo): la primera columna sale como `ï..AGE` o `X.U.FEFF.SEX`. Pasa en Audiometry, Vision, BodyTemperatures y la base de depresión. Se arregla con `fileEncoding = "UTF-8-BOM"` o refiriéndote a la columna por posición.

4. **Nombres con espacios**: `RIGHT THRESHOLD` queda como `datos$RIGHT.THRESHOLD`. Mira `names(datos)`.
5. **Números leídos como texto**: en icfes_2016, `punt_matematicas` trae una fila dañada y queda como `chr`. Conviértela con `as.numeric()`. El aviso "NAs introducidos por coerción" es normal.
6. **Faltantes (NA)**: `mean(x)` da `NA`. Usa `mean(x, na.rm = TRUE)`. `t.test` los quita solo.
7. **Códigos**: en Audiometry `GENDER` 0 = mujer y 1 = hombre; en insurance `smoker` vale `"yes"`/`"no"`; en icfes el género es `"F"`/`"M"` y los departamentos van en MAYÚSCULAS sin tilde (`"ANTIOQUIA"`, `"CUNDINAMARCA"`, `"BOGOTA"`).

5.3 Filtrar, separar grupos y contar

```
set.seed(2026)                                          # muestra reproducible
muestra = datos[sample(nrow(datos), 10000), ]           # muestra aleatoria simple de 10000 filas
ant = muestra[muestra$estu_depto_reside == "ANTIOQUIA", ]          # filtrar filas
mujeres30 = datos[datos$GENDER == 0 & datos$AGE > 30, ]            # dos condiciones: &
fum = datos$charges[datos$smoker == "yes"]              # una variable para un grupo
x = sum(datos$smoker == "yes"); n = nrow(datos)         # conteo de éxitos y total
x/n                                                     # proporción muestral
normal = datos$RIGHT.THRESHOLD >= 0 & datos$RIGHT.THRESHOLD <= 30   # condición "entre"
```

5.4 Plantillas listas para copiar

```r
# ---- Una media (IC o prueba) ----
t.test(x, conf.level = 0.95)                                  # IC bilateral
t.test(x, mu = 15, alternative = "less")                      # H1: mu < 15
# ---- Dos medias independientes ----
var.test(x1, x2, conf.level = 0.95)                           # ?`contiene 1?
t.test(x1, x2, var.equal = TRUE)                              # si contiene 1
t.test(x1, x2)                                                # Welch si no contiene 1
t.test(x1, x2, mu = 6, alternative = "greater")               # H1: mu1 - mu2 > 6
# ---- Pareadas ----
t.test(antes, despues, paired = TRUE, conf.level = 0.95)
# ---- Proporciones ----
prop.test(x, n, conf.level = 0.90, correct = FALSE)                       # IC una p
prop.test(x, n, p = 0.86, alternative = "two.sided", correct = FALSE)      # prueba una p
prop.test(c(x1, x2), c(n1, n2), conf.level = 0.93, correct = FALSE)        # IC p1 - p2
prop.test(c(x1, x2), c(n1, n2), alternative = "greater", correct = FALSE)  # H1: p1 > p2
# ---- Varianza (chi-cuadrado, a mano) ----
n = length(x); s2 = var(x); a = 0.05
(n-1)*s2/qchisq(1-a/2, n-1); (n-1)*s2/qchisq(a/2, n-1)   # IC para sigma^2
chi = (n-1)*s2/sigma0^2; pchisq(chi, n-1, lower.tail = FALSE)   # p, cola derecha
# ---- Efecto y potencia ----
library(effsize); cohen.d(x, NA, mu = 15)
power.t.test(n = length(x), delta = abs(mean(x)-15), sd = sd(x),
             sig.level = 0.05, type = "one.sample", alternative = "one.sided")
```

5.5 ¿Y el supuesto de normalidad?

Muchos ejercicios dicen "verificando el supuesto que requiera". Con las funciones de clase la verificación es **gráfica**:

```r
m = datos$minutos                       # la variable que vas a analizar
hist(m, probability = TRUE, col = "lightblue", border = "white")
lines(density(m), col = "blue", lwd = 2)
curve(dnorm(x, mean = mean(m), sd = sd(m)), add = TRUE, col = "red", lty = 2)   # dentro de curve
     la x es fija
```

Si el histograma se parece a la campana roja (simétrico, sin colas raras ni atípicos extremos), el supuesto es razonable. Si $n \geq 30$, el TLC respalda el uso de t aunque la población no sea perfectamente normal. Una prueba formal como `shapiro.test(x)` ($p > 0.05$: no hay evidencia contra la normalidad) no aparece en tus scripts: úsala solo si la profe la acepta.

5.6 Simulacro (Bloque 4)

Simulacro de 100 minutos

1. Toma el **Parcial 2 de 2024-2** (Audiometry + 2 puntos teóricos). Cronómetro: 100 minutos. Sin mirar guías.
2. Luego, en 30 minutos, el preparcial parte 3: #3 (Martínez), #4 (Carseats) y #6 (V/F).
3. Califícate con la Guía de solución. Por cada punto perdido, escribe en una línea *por qué* lo perdiste (concepto, cuenta, R o redacción).
4. Haz los retos de la sección 6 y revisa la hoja de trampas (sección 7) solo para los errores que cometiste.

Cómo administrar el tiempo en el parcial

- Empieza por lo que domines. La teoría (MLE, consistencia) suele ser corta si sabes la receta.
- En la parte de R, escribe en la hoja el **código usado** y los **números clave** de la salida (estadístico, gl, p-valor, IC). La conclusión va en palabras del problema.
- Siempre cierra con **supuestos**: muestras aleatorias e independientes; normalidad (o n grande y TLC); $np \geq 5$ y $nq \geq 5$ para proporciones; qué asumiste sobre las varianzas y por qué.

6 Retos tipo Externado (con respuesta)

Son variaciones más difíciles de lo que ya viste, escritas para entrenar las trampas. Haz cada uno en papel. Las respuestas están en la caja verde de cada reto.

Reto 1 · MLE sesgado pero consistente

$Y_1, \ldots, Y_n \sim U(0, \theta)$. (a) Muestra que el MLE $\hat{\theta} = Y_{(n)}$ es sesgado. (b) Construye uno insesgado. (c) ¿El MLE es consistente?

Respuesta

(a) $\mathrm{E}(Y_{(n)}) = \frac{n\theta}{n+1}$, con sesgo $-\frac{\theta}{n+1}$. (b) $\frac{n+1}{n} Y_{(n)}$. (c) Sí: el sesgo $\to 0$ y $\mathrm{V}(Y_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)} \to 0$, así que ECM $\to 0$.

Reto 2 · Suficiencia y MLE con soporte que depende de θ

$f(y \mid \theta) = e^{-(y-\theta)}$ para $y \geq \theta$. Halla un estadístico suficiente y el MLE.

Respuesta

$L(\theta) = e^{-\sum y_i + n\theta}\, \mathbb{I}(y_{(1)} \geq \theta) = \underbrace{e^{n\theta}\mathbb{I}(y_{(1)} \geq \theta)}_{g(y_{(1)}, \theta)} \cdot \underbrace{e^{-\sum y_i}}_{h}$, así que $Y_{(1)}$ (el mínimo) es suficiente. L crece con θ hasta $y_{(1)}$, luego $\hat{\theta}_{MLE} = Y_{(1)}$. No se deriva.

Reto 3 · ¿Insesgado siempre es mejor?

En una normal, $\mathrm{V}(S^2) = \frac{2\sigma^4}{n-1}$. Compara por ECM a S^2 y a $\hat{\sigma}^2 = \frac{n-1}{n}S^2$.

Respuesta

$\mathrm{ECM}(S^2) = \frac{2\sigma^4}{n-1}$. $\mathrm{ECM}(\hat{\sigma}^2) = \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} + \left(\frac{\sigma^2}{n}\right)^2 = \frac{(2n-1)\sigma^4}{n^2}$. $\frac{2n-1}{n^2} < \frac{2}{n-1} \iff -3n+1 < 0$, que se cumple siempre. El estimador **sesgado** tiene **menor** ECM: insesgado no implica mejor.

Reto 4 · Reconstruir una salida de R

Una salida de Welch muestra `t = 2.1429, df = 30.5` y `95 percent confidence interval: 0.1428 5.8572`. (a) $\bar{x}_1 - \bar{x}_2$ y SE. (b) p-valor de dos colas y decisión al 5% y al 1%. (c) p-valor si $H_1 : \mu_1 - \mu_2 > 0$.

Respuesta

(a) e.p. $= \frac{0.1428+5.8572}{2} = 3.0$, m.e. $= 2.857$, $t_{0.025;30.5} = 2.041$, SE $= \frac{2.857}{2.041} = 1.40$. Comprobación: $3/1.4 = 2.14$. (b) p $= 2\,$`pt(-2.1429, 30.5)` $= 0.040$: se rechaza al 5% y no al 1%. (c) p $= 0.020$, la mitad.

Reto 5 · Mismo efecto, distinto n

$\hat{p} = 0.58$. Prueba $H_0 : p \leq 0.5$ vs. $H_1 : p > 0.5$ con $\alpha = 0.05$, primero con $n = 100$ y luego con $n = 200$.

Respuesta

Con $n = 100$: $z_c = \frac{0.08}{\sqrt{0.25/100}} = 1.60$, p $= 0.055$, no se rechaza. Con $n = 200$: $z_c = 2.26$, p $= 0.012$, se rechaza. La magnitud del efecto es la misma (8 puntos). Lo que cambia es la significancia: por eso se reporta también el tamaño del efecto.

Reto 6 · Pareado mal analizado

Con los datos de las llantas, compara `t.test(A, B, paired = TRUE)` con `t.test(A, B)`.

Respuesta

Pareado: $t = 12.83$, p $= 0.0002$, hay diferencia. Independiente (Welch): $t = 0.57$, p $= 0.58$, "no hay diferencia". El análisis equivocado borra el efecto porque la variabilidad entre autos tapa la diferencia entre llantas.

Reto 7 · Varianza a dos colas

$n = 12$, $s^2 = 2.5$. Prueba $H_0 : \sigma^2 = 1.5$ vs. $H_1 : \sigma^2 \neq 1.5$ con $\alpha = 0.05$.

Respuesta

$\chi^2_c = \frac{11(2.5)}{1.5} = 18.33$. Críticos: `qchisq(0.025,11)`$= 3.82$ y `qchisq(0.975,11)`$= 21.92$. Como $3.82 < 18.33 < 21.92$, no se rechaza. p $= 2\,$`pchisq(18.33, 11, lower.tail=FALSE)` $= 0.148$.

Reto 8 · Tamaño de muestra sin información previa

¿Qué n necesitas para estimar una proporción con error máximo 0.03 y 95% de confianza?

Respuesta

$n = \frac{1.96^2(0.5)(0.5)}{0.03^2} = 1067.1$, así que $\mathbf{n = 1068}$. Siempre se redondea hacia arriba, y se usa $p = 0.5$ porque es el peor caso.

Reto 9 · Verdadero o falso (conceptos finos)

a) Un intervalo de predicción del 95% contiene al 95% de la población.
b) Si $n \to \infty$, el IC de μ se encoge a un punto, pero el IP no.
c) Subir α de 0.05 a 0.10 (mismo n y mismo efecto) aumenta la potencia.
d) Si el IC del 95% para $\mu_1 - \mu_2$ es (0.2, 3.1), la prueba de dos colas con $\alpha = 0.05$ rechaza $H_0 : \mu_1 = \mu_2$.
e) Un p-valor de 0.20 demuestra que H_0 es verdadera.
f) Si la cobertura simulada de un IC del 95% da 0.947 con 10 000 simulaciones, el método está mal.

Respuesta

a) **F**: eso es tolerancia; el IP es para *una* observación futura. b) **V**. c) **V**. d) **V**: el 0 queda fuera del IC. e) **F**: no rechazar no demuestra H_0. f) **F**: es muy cercana a 0.95, y el error de simulación ronda ± 0.004. En el caso de Wald sí hay un leve sesgo hacia abajo, pero "mal" es exagerado.

Reto 10 · Eficiencia que depende de n

Con $\mathrm{V}(\hat{\theta}_1) = \frac{1}{12n}$ y $\mathrm{V}(\hat{\theta}_2) = \frac{n}{(n+1)^2(n+2)}$ (preparcial parte 1, #3), ¿para qué n conviene cada uno?

Respuesta

$\mathrm{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{12n^2}{(n+1)^2(n+2)}$. Para $n = 2, \ldots, 7$ es mayor que 1 (gana $\hat{\theta}_1$); para $n \geq 8$ es menor que 1 (gana $\hat{\theta}_2$). Con $n = 1$ son el mismo estimador.

7 Hoja de trampas para el viernes (Bloque 5)

7.1 Las 25 trampas que más puntos cuestan

1. $\mathrm{V}(X-Y) = \mathrm{V}(X) + \mathrm{V}(Y)$: se **suma**.
2. $\mathrm{V}(aX+b) = a^2\,\mathrm{V}(X)$: la constante sale **al cuadrado**.
3. $\mathrm{ECM} = \mathrm{V} + \mathrm{Sesgo}^2$; si es insesgado, ECM = V.
4. $\mathrm{eff}(\hat\theta_1, \hat\theta_2) = \mathrm{V}(\hat\theta_2)/\,\mathrm{V}(\hat\theta_1)$: si es < 1 gana $\hat\theta_2$.
5. La eficiencia puede depender de n; revisa para qué n gana cada uno.
6. Consistencia (profe): insesgado y $\mathrm{V} \to 0$. Si es sesgado: sesgo $\to 0$ y $\mathrm{V} \to 0$.
7. Suficiencia: h **no** puede tener θ; no olvides la indicadora cuando el soporte depende de θ.
8. MLE de la uniforme: $Y_{(n)}$, sin derivar. El de momentos es $2\bar{Y}$.
9. El MLE de σ^2 divide por n (sesgado); S^2 divide por $n-1$.
10. Un estimador no puede contener el parámetro.
11. Críticos con valor absoluto: `abs(qnorm(a/2))`, `abs(qt(a/2, gl))`.
12. IC de σ^2: el χ^2 **grande** va con el límite **inferior**.
13. Para σ, raíz a los límites del IC de σ^2.
14. Diferencias: el 0 adentro significa iguales; todo +, $\mu_1 > \mu_2$; todo −, $\mu_1 < \mu_2$.
15. Cociente de varianzas: el 1 adentro significa iguales.
16. Si no dicen nada de las varianzas, haz `var.test` y justifica. Sin información, la profe asume diferentes (Welch).
17. Pareadas = mismo sujeto dos veces. Usa `paired = TRUE`.
18. Proporciones: IC con $\hat p$; prueba con p_0; dos proporciones con $\hat p$ agrupada.
19. `prop.test`: `X-squared` $= z_c^2$. Siempre `correct = FALSE`.
20. `t.test` con `alternative` imprime un IC **unilateral**.
21. `mu =` en dos muestras es la diferencia hipotética d_0 (ej. 6 o 0.5), no la media.
22. H_0 lleva el igual; H_1 lleva lo que el investigador quiere probar.
23. No rechazar no prueba H_0: "los datos no dan evidencia de…".
24. El p-valor no es $P(H_0$ verdadera$)$.
25. `normtol.int`: `alpha` = 1−confianza; `P` = proporción de la población.

7.2 Fórmulas en una página

Sesgo / ECM	$\mathrm{B} = \mathrm{E}(\hat{\theta}) - \theta \quad \mathrm{ECM} = \mathrm{V}(\hat{\theta}) + \mathrm{B}^2$
Eficiencia	$\mathrm{eff}(\hat{\theta}_1, \hat{\theta}_2) = \mathrm{V}(\hat{\theta}_2)/\,\mathrm{V}(\hat{\theta}_1)$
Suficiencia	$L(\theta) = g(u, \theta)\, h(y)$
MLE	$L \to \ln L \to \dfrac{d}{d\theta} = 0 \to \hat{\theta}$ (soporte con θ: usar el máximo o el mínimo)
IC media	$\bar{x} \pm z\dfrac{\sigma}{\sqrt{n}} \quad \bar{x} \pm t_{n-1}\dfrac{s}{\sqrt{n}}$
IC proporción	$\hat{p} \pm z\sqrt{\hat{p}\hat{q}/n}$
IC varianza	$\left[\dfrac{(n-1)s^2}{\chi^2_{\text{grande}}},\ \dfrac{(n-1)s^2}{\chi^2_{\text{pequeño}}}\right]$
IC dif. medias	z: $\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}$ pooled: $t_{n_1+n_2-2}\sqrt{s_p^2(\dfrac{1}{n_1} + \dfrac{1}{n_2})}$ Welch: $t_{gl}\sqrt{\dfrac{s_1^2}{n_1} + \dfrac{s_2^2}{n_2}}$
IC pareadas	$\bar{d} \pm t_{n-1}\dfrac{s_d}{\sqrt{n}}$
IC dif. proporciones	$(\hat{p}_1 - \hat{p}_2) \pm z\sqrt{\dfrac{\hat{p}_1\hat{q}_1}{n_1} + \dfrac{\hat{p}_2\hat{q}_2}{n_2}}$
IC cociente	$\left[\dfrac{s_1^2/s_2^2}{F_{1-\alpha/2;gl_1,gl_2}},\ \dfrac{s_1^2}{s_2^2}F_{1-\alpha/2;gl_2,gl_1}\right]$
Predicción	$\bar{x} \pm t_{n-1}\, s\sqrt{1 + \dfrac{1}{n}}$ (σ conocida: $z\,\sigma\sqrt{1 + \dfrac{1}{n}}$)
Tolerancia	$\bar{x} \pm k\, s$ `normtol.int(x, alpha = 1-conf, P = prop, side = 2, method = "EXACT")`
Pruebas	$z_c = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \quad t_c = \dfrac{\bar{x} - \mu_0}{s/\sqrt{n}} \quad z_c = \dfrac{\hat{p} - p_0}{\sqrt{p_0 q_0/n}} \quad \chi^2_c = \dfrac{(n-1)s^2}{\sigma_0^2} \quad F_c = \dfrac{s_1^2}{s_2^2}$
Dos proporciones	$z_c = \dfrac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}(\frac{1}{n_1} + \frac{1}{n_2})}},\ \hat{p} = \dfrac{x_1 + x_2}{n_1 + n_2}$
Efecto	$d = \dfrac{\bar{x} - \mu_0}{s}$ o $\dfrac{\bar{x}_1 - \bar{x}_2}{s_p}$: 0.2 pequeño, 0.5 mediano, 0.8 grande
Regla	p-valor $< \alpha \Rightarrow$ se rechaza H_0

7.3 Frases de respuesta (copia el estilo)

Intervalos

"Con un nivel de confianza del 95%, el tiempo promedio de espera está entre 6.02 y 7.59 minutos."
"Con 90% de confianza la diferencia de medias está entre −36.4 y 11.8. Como el intervalo contiene el 0, los tiempos medios son aproximadamente iguales."
"El IC del cociente de varianzas (2.21, 174.75) no contiene el 1 y ambos límites son mayores que 1, así que la línea 1 tiene mayor varianza (es menos consistente)."
"El próximo paquete tendrá entre 94% y 98.4%" (predicción). "Con 95% de confianza, al menos el

90% de los paquetes tiene entre 94.5% y 97.9%" (tolerancia).

Pruebas

"Con un nivel de significancia de 0.01, se rechaza H_0 ($p = 0.0048 < 0.01$); los datos dan evidencia de que hay diferencia en los saldos medios de las dos sucursales."
"Con un nivel de significancia de 0.05, no se rechaza H_0 ($t_c = -1.49 > -1.729$); los datos no dan evidencia de que las calificaciones medias sean menores a 80 puntos."
"$|d| = 0.53$: efecto mediano. Potencia $= 0.886$: si el efecto existe, la prueba lo detecta con probabilidad 88.6%."

Supuestos (casi siempre preguntan)

Muestras aleatorias; independencia entre observaciones (y entre grupos si son independientes); población normal o n grande (TLC) para medias; $n\hat{p} \geq 5$ y $n\hat{q} \geq 5$ para proporciones; lo que asumiste de las varianzas (iguales/diferentes, con su justificación por `var.test`); varianzas poblacionales conocidas si usaste z.

¡Éxitos el viernes!

Duerme bien el jueves. Un cerebro descansado vale más que dos horas extra de repaso a la madrugada.