Preparcial Corte 2, parte 3

Docente: Diana Moreno y Diego Niño

1. En el archivo **muestraicfes.csv**, se encuentran los datos resumidos de una muestra de 1106 personas que presentaron el ICFES en el año 2016.

   a) Suponga que la varianza poblacional para el puntaje de lectura crítica, de quienes tienen internet es de 89.596 y de 82.617 para quienes no tienen. Con un nivel de significancia de 0.01, los datos dan evidencia de que el puntaje medio en lectura crítica, de quienes tienen internet es mayor de los que no tienen internet. Use el método del p-valor.

   b) ¿Qué supuestos usó para solucionar el punto anterior?

2. Los datos **basedepresespanol.csv** proceden de un estudio de 2015 realizado por el Busara Center en el condado rural de Siaya, cerca del lago Victoria, en el oeste de Kenia. La encuesta incluye más de 70 características, entre ellas información sobre la composición de los hogares, la actividad económica, los flujos financieros y la salud. Además, se pidió a los participantes en el estudio que completaran una herramienta de detección de la depresión. Estos datos son difíciles de recopilar en masa, debido a lo delicado de su contenido y a la necesidad de personal formado y procedimientos de remisión. A partir de esta información:

   a) Con un nivel de significancia de 0.01, el investigador desea saber si el promedio de edades de las mujeres excede en 6 años al promedio de edades de los hombres. ¿Los datos dan evidencia sobre la hipótesis del investigador? Realice todo el proceso para justificar su respuesta.

   b) ¿Qué supuestos uso para dessarrollar el punto anterior?

3. El señor Martínez, el nuevo gerente de un almacén de cadena, está interesado en el porcentaje de clientes totalmente satisfechos con su almacén. El gerente anterior tenía el 86 % de clientes totalmente satisfechos y el señor Martínez asegura que lo mismo se cumple hoy. El señor Martínez obtuvo una muestra de 187 clientes y encontró que 157 estaban satisfechos por completo.

   a) ¿Cuál es el error tipo I?

   b) Con un nivel de significancia del 1 %, ¿existe evidencia de que la afirmación del señor Martínez es válida?

4. Las siguientes salidas contienen información sobre la venta de sillas infantiles en 400 tiendas distintas. Para cada una de las 400 tiendas se han registrado 11 variables. Entre las que tenemos **Ventas(Sales)**,Ventas unitarias (en miles) en cada local,**Precio de la competencia(CompPrice)**,Precio cobrado por el competidor en cada establecimiento,**Ingresos (Income)**Nivel de ingresos de la comunidad (en miles de dólares),**Urbano (Urban)** Un factor con niveles No y Sí para indicar si la tienda está en una ubicación urbana o rural, entre otras.

```
F test to compare two variances

data:  urbano$Sales and rural$Sales
F = 1.0218, num df = 281, denom df = 117, p-value = 0.9072
alternative hypothesis: true ratio of variances is not equal to 1
92 percent confidence interval:
 0.7708313 1.3316507
sample estimates:
ratio of variances
          1.021767

          Two Sample t-test

data:  urbano$Sales and rural$Sales
t = -1.9206, df = 398, p-value = 0.02775
alternative hypothesis: true difference in means is less than 0.5
95 percent confidence interval:
     -Inf 0.415701
sample estimates:
mean of x mean of y
 7.468191  7.563559
```

A partir de las salidas anteriores conteste lo siguiente:

a) ¿Qué significa mean of x y mean of y?_____

b) Un intervalo de confianza de _____ % para la diferencia de medias es _____.

c) La interpretación del intervalo en *b*) significa que _____

d) Lo grados de libertad son iguales a: _____

e) La hipótesis alterna para la diferencia de medias es _____

f) El estadístico de prueba para la diferncia de medias es _____

g) El p-valor para la prueba de hipótesis de la diferencia de medias es _____

h) A un nivel de significancia de 0.01, para la prueba de hpótesis para la diferencia de medias, se concluye que_____

i) ¿Qué supuestos se deben usar para realizar los numerales anteriores?

5. Los datos de zarigüeyas consta de nueve mediciones morfométricas de cada una de las 104 zarigüeyas de cola de cepillo de montaña, atrapadas en siete sitios australianos desde el sur de Victoria hasta el centro de Queensland. Las variables medidas están en el arcivo possum.txt y possum.csv. Se desea saber si la proporción de hembras que se atraparon en Victoria es mayor que la proporción de hembras que se atraparon en Nueva Gales del Sur o Queensland. Use un nivel de significancia de 0.05 y el método del punto crítico.

6. Conteste Verdadero o Falso, según corresponda, justifique sólo las falsas.

   a) _____ El p-valor representa la probabilidad de que la hipótesis nula sea verdadera dado que se observaron los datos de la muestra.

   b) _____ Si el p-valor es menor que el nivel de significancia α, se rechaza la hipótesis nula.

   c) _____ Un p-valor de 0.03 indica que existe un 97 % de probabilidad de que la hipótesis alternativa sea verdadera.

   d) _____ La potencia de una prueba es la probabilidad de rechazar correctamente una hipótesis nula falsa.

   e) _____ Aumentar el tamaño de muestra suele incrementar la potencia de una prueba estadística.

   f) _____El tamaño del efecto mide únicamente si un resultado es estadísticamente significativo.

   g) _____ Dos estudios pueden tener el mismo p-valor pero diferentes tamaños del efecto.

   h) _____Cometer un error tipo I significa rechazar una hipótesis nula que en realidad es verdadera.

   i) _____ Cometer un error tipo II significa no rechazar una hipótesis nula que en realidad es falsa.

   j) _____Reducir el nivel de significancia de 0.05 a 0.01 disminuye la probabilidad de cometer un error tipo I.

7. Una empresa implementó un programa de entrenamiento físico para sus trabajadores. Históricamente, el tiempo promedio para completar una prueba de resistencia era de 15 minutos. Después de aplicar el programa a un grupo de empleados, se registraron los siguientes tiempos (en minutos):

   14, 13, 15, 12, 14, 13, 11, 14, 12, 13, 15, 12, 14, 13, 12, 11, 14, 13, 12, 14

   a) Realice la prueba de hipótesis para determinar si el programa redujo el tiempo promedio de la prueba. Utilice un nivel de significancia de $\alpha = 0.05$.

   b) Calcule el tamaño del efecto utilizando el estadístico de Cohen (d) e interprételo.

   c) Calcule la potencia de la prueba e interprete el resultado.

8. Una universidad instaló un nuevo sistema de iluminación inteligente en un edificio académico. Históricamente, el consumo promedio diario de energía era de 100 kWh. Durante 24 días posteriores a la instalación, se registraron los siguientes consumos diarios (kWh):

   95, 97, 92, 98, 94, 96, 93, 97, 91, 95, 94, 96, 92, 98, 95, 93, 94, 96, 92, 97, 95, 94, 93, 96

   a) Realice la prueba de hipótesis para evaluar si el nuevo sistema disminuyó el consumo promedio de energía. Utilice un nivel de significancia de $\alpha = 0.05$.

b) Calcule el tamaño del efecto utilizando el estadístico de Cohen (d).

c) Calcule la potencia de la prueba e interprete el resultado.

9. Una empresa desea evaluar si una nueva capacitación reduce el tiempo necesario para atender solicitudes de clientes. Se conoce que:

   - Grupo control (sin capacitación): $\mu_C = 20$ minutos, $\sigma_C = 4$ minutos.
   - Grupo tratado (con capacitación): $\mu_T = 18$ minutos, $\sigma_T = 4$ minutos.

   Utilice simulación Monte Carlo para generar muestras independientes de ambos grupos y construir intervalos de confianza para la diferencia de medias $\mu_C - \mu_T$ usando la distribución t.

   a) Modifique la función suministrada para estimar la cobertura de un IC para $\mu_C - \mu_T$.

   b) Considere tamaños muestrales $n_C = n_T = 15$ y realice al menos 1000 simulaciones.

   c) Estime la probabilidad de cobertura de un IC del 95 %.

   d) Repita el procedimiento con tamaños muestrales de 30 y 50 observaciones por grupo.

   e) Compare los resultados y explique qué ocurre con la precisión de los intervalos cuando aumenta el tamaño de muestra.

   f) Analice si la cobertura obtenida es cercana al nivel nominal del 95 %.

10. Una empresa de logística desea controlar el tiempo necesario para clasificar paquetes en su centro de distribución. Se toma una muestra aleatoria de tiempos (en minutos) y se obtienen los siguientes valores:

    $$14,\ 16,\ 15,\ 18,\ 17,\ 15,\ 16,\ 14,\ 17,\ 15$$

    Utilice estos datos para calcular tres tipos de intervalos y realizar interpretaciones que ilustren las diferencias entre ellos en el contexto del sistema. Para todos los cálculos suponga una distribución aproximadamente normal.

    a) Intervalo de confianza para la media μ.

    b) Intervalo de predicción para el tiempo de clasificación de un solo paquete futuro x_0.

    c) Límites de tolerancia que contengan el 90 % de los tiempos de clasificación de los paquetes.

11. Una planta embotelladora realiza controles periódicos del volumen de llenado de sus botellas de agua. Se toma una muestra aleatoria de botellas y se registran los siguientes volúmenes (en mL):

    $$498,\ 501,\ 503,\ 500,\ 497,\ 502,\ 499,\ 501,\ 500,\ 504$$

    Utilice estos datos para calcular tres tipos de intervalos y realizar interpretaciones que ilustren las diferencias entre ellos en el contexto del proceso productivo. Para todos los cálculos suponga una distribución aproximadamente normal.

    Calcular (99 % de confianza):

    a) Intervalo de confianza para la media μ.

    b) Intervalo de predicción para el volumen de una botella futura x_0.

    c) Límites de tolerancia que contengan el 95 % de las botellas producidas.