Preparcial-parte 2

Docente: Diana Moreno y Diego Niño

1. Se lleva a cabo un experimento para comparar el contenido de alcohol en una salsa de soya en dos líneas de producción diferentes. La producción se supervisa ocho veces al día. A continuación se presentan los datos.

   ```
   Línea de producción 1.
   0.48 0.39 0.42 0.52 0.40 0.48 0.52 0.52
   Línea de producción 2.
   0.38 0.37 0.39 0.41 0.38 0.39 0.40 0.39
   ```

   Suponga que ambas poblaciones son normales. Se sospecha que la línea de producción 1 no está produciendo tan consistentemente como la línea 2 en términos de contenido de alcohol. ¿Existe alguna diferencia entre el contenido promedio de alcohol de la línea de producción uno con la dos? Explique su respuesta. Use un nivel de confianza de 99 %.

2. En el archivo icfes_ 2016.csv, se encuentran los datos resumidos de personas que presentaron el ICFES en el año 2016. Use R para seleccionar una muestra aleatoria simple de tamaño 10000, filtre por el departamento de Antioquia y Cundinamarca.

   a) Halle un intervalo de confianza para la diferencia de promedios en los puntajes de matemáticas para estos dos departamentos. Interprete el resultado.

   b) Calcule un intervalo de confianza para la proporción de mujeres que presentaron la prueba en Cundinamarca.Interprete el resultado.

   c) Calcule un intervalo de confianza para la proporción de hombres que presentaron la prueba en Antioquia Interprete el resultado.

   d) ¿Qué supuesto se deben mantener para poder construir los intervalos en $a), b)$ y $c)$?

3. Considere la situación del estudio de caso 9.1 de la página 281, con una muestra más grande de piezas metálicas. Los diámetros son los siguientes:

   ```
   1.01, 0.97,1.03, 1.04, 0.99, 0.98,
    1.01, 1.03, 0.99, 1.00, 1.00, 0.99,
   0.98, 1.01, 1.02, 0.99
   ```

   suponer una distribución normal. Haga lo siguiente:

   a) Calcule un intervalo de confianza del 99 % de la media del diámetro.

   b) Calcule un intervalo de predicción del 99 % en la medición del siguiente diámetro.

   c) Calcule un intervalo de tolerancia del 99 % para la cobertura del 95 % central de la distribución de diámetros.

4. En un estudio realizado por el Departamento de Zoología del Virginia Tech con el fi n de conocer la cantidad de ortofósforo en el río, se recolectaron 15 "muestras" de agua en una determinada estación ubicada en el río James. La concentración del químico se midió en miligramos por litro. Suponga que la media en la estación de muestreo no es tan importante como la distribución de las concentraciones del químico en los extremos superiores. El interés se centra en saber si las concentraciones en estos extremos son demasiado elevadas. Las lecturas de las 15 muestras de agua proporcionaron una media muestral de 3.84 miligramos por litro y una desviación estándar muestral de 3.07 miligramos por litro. Suponga que las lecturas son una muestra aleatoria de una distribución normal. Calcule un intervalo de predicción (límite de predicción superior del 95 %) y un límite de tolerancia (un límite de tolerancia superior del 95 % que excede al 95 % de la población de valores). Interprete ambos límites, es decir, especifique qué indica cada uno acerca de los extremos superiores de la distribución de ortofósforo en la estación de muestreo.

5. **Estudio de Caso: Análisis de Costos Médicos y Seguros de Salud**

   Una compañía de seguros de salud desea analizar los datos de sus beneficiarios para entender qué factores demográficos y de estilo de vida impactan más en los costos médicos facturados. Se tiene una muestra aleatoria de 1338 asegurados extraída de la base de datos pública *Medical Cost Personal Datasets* (archivo `insurance.csv`).

   La base de datos contiene información sobre la edad (`age`), género (`sex`), índice de masa corporal (`bmi`), número de hijos (`children`), condición de fumador (`smoker`), región de residencia (`region`) y los cargos médicos anuales facturados por el seguro (`charges`).

   Misión Analítica

   Utilizando el software R, y asumiendo que las variables continuas provienen de poblaciones aproximadamente normales, calcule e interprete los siguientes intervalos de confianza para ayudar a la aseguradora a tomar decisiones estratégicas:

   a) Calcule un intervalo de confianza del 95 % para el Índice de Masa Corporal (`bmi`) promedio de todos los asegurados. Con base en el resultado, ¿se puede afirmar con un 95 % de confianza que la población general de asegurados se encuentra en el rango de sobrepeso (BMI $\geq$ 25)?

   b) Construya un intervalo del 99 % para la diferencia en los cargos médicos promedio (`charges`) entre fumadores y no fumadores. ¿Existe evidencia estadística concluyente de que el hábito de fumar incrementa los costos para la aseguradora?

   c) Calcule un intervalo del 90 % para la proporción poblacional de asegurados que son fumadores en esta cartera de clientes.

   d) Construya un intervalo del 95 % para comparar la proporción de fumadores entre hombres (`male`) y mujeres (`female`). ¿Existe una diferencia significativa en la prevalencia del tabaquismo según el género en esta población?

   e) La aseguradora necesita medir la volatilidad en la salud de sus clientes. Calcule un intervalo del 95 % para la varianza del Índice de Masa Corporal (`bmi`) de toda la población. *Nota: Considere la distribución Chi-cuadrado para este cálculo.*

f) Construya un intervalo del 95 % para el cociente de varianzas de los cargos médicos (`charges`) entre fumadores y no fumadores. ¿Es razonable asumir homocedasticidad (varianzas iguales) entre los costos de ambos grupos si se quisiera estimar un modelo de regresión posterior?

6. Cargue el conjunto de datos `BodyTemp50` del paquete `Lock5Data`. Este es un conjunto de datos de 50 adultos sanos. Una de las columnas de este conjunto de datos es el Pulso (`Pulse`) de los 50 puntos de datos, que es el número de latidos del corazón por minuto.

   a) Cree un histograma de los valores de pulso observados. Comente sobre el gráfico y los aspectos del mismo que podrían ser de interés científico. El código a continuación le ayudará a cargar los datos; queremos usar la variable `Pulse`.

   ```
   data( BodyTemp50, package='Lock5Data' )
   #?BodyTemp50
   ```

   b) Calcule la media muestral $\bar{x}$ y la desviación estándar muestral s de los pulsos.

   c) Cree un conjunto de datos de 10000 réplicas bootstrap de $\bar{x}^*$.

   d) Cree un histograma de las réplicas bootstrap. Calcule la media y la desviación estándar de esta distribución. Note que la desviación estándar de la distribución a menudo se llama Error Estándar de $\bar{x}$ y lo denotaremos como $\hat{\sigma}_{\bar{x}}$.

   e) Usando las réplicas bootstrap, cree un intervalo de confianza del 95 % para μ, la frecuencia cardíaca promedio de los adultos.

   f) Calcule el intervalo

   $$(\bar{x} - 2 \cdot \hat{\sigma}_{\bar{x}}\,, \quad \bar{x} + 2 \cdot \hat{\sigma}_{\bar{x}})$$

   y comente sobre su similitud con el intervalo que calculó en la parte (e).

7. Cargue el conjunto de datos `EmployedACS` del paquete `Lock5Data`. Este es un conjunto de datos extraído de los resultados de la Encuesta sobre la Comunidad Estadounidense (American Community Survey) que la Oficina del Censo de EE. UU. realiza mensualmente y que debería ser representativo de los trabajadores estadounidenses. La columna `HoursWk` representa el número de horas trabajadas por semana.

   a) Cree un histograma de las horas trabajadas observadas. Comente sobre el gráfico y los aspectos del mismo que podrían ser de interés científico.

   b) Calcule la media muestral $\bar{x}$ y la desviación estándar muestral s de las horas trabajadas por semana.

   c) Cree un conjunto de datos de 10000 réplicas bootstrap de $\bar{x}^*$.

   d) Cree un histograma de las réplicas bootstrap. Calcule la media y la desviación estándar de esta distribución. Note que la desviación estándar de la distribución a menudo se llama Error Estándar de $\bar{x}$ y lo denotaremos como $\sigma_{\bar{x}}$.

e) Usando las réplicas bootstrap, cree un intervalo de confianza del 95 % para μ, el promedio de horas trabajadas por semana.

f) Calcule el intervalo

$$(\bar{x} - 2 \cdot \hat{\sigma}_{\bar{x}}\,, \quad \bar{x} + 2 \cdot \hat{\sigma}_{\bar{x}})$$

y comente sobre su similitud con el intervalo que calculó en la parte (e).

Para cada uno de los siguientes ejercicios, diseñe e implemente una función de simulación Monte Carlo en `R` que genere B muestras independientes bajo las condiciones especificadas, evalúe el intervalo de confianza correspondiente y calcule la **cobertura empírica** (proporción de intervalos que contienen al verdadero parámetro poblacional).

8. Sean $X_1 \sim N(\mu_1, \sigma_1^2)$ y $X_2 \sim N(\mu_2, \sigma_2^2)$ dos poblaciones normales e independientes con varianzas conocidas σ_1^2 y σ_2^2.

   a) Formule el intervalo de confianza teórico del $(1-\alpha) \times 100\,\%$ para la diferencia de medias $\mu_1 - \mu_2$:

   $$(\bar{X}_1 - \bar{X}_2) \pm Z_{1-\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

   b) Mediante una simulación Monte Carlo con $B = 10\,000$ repeticiones, estime la cobertura empírica considerando los siguientes parámetros: $n_1 = 30$, $n_2 = 25$, $\mu_1 = 50$, $\mu_2 = 45$, $\sigma_1 = 4$, $\sigma_2 = 5$ y un nivel de confianza nominal del 95 % ($\alpha = 0.05$).

9. Sean $X_1 \sim N(\mu_1, \sigma^2)$ y $X_2 \sim N(\mu_2, \sigma^2)$ dos poblaciones normales e independientes donde la varianza común σ^2 es desconocida.

   a) Construya la estimación del intervalo de confianza empleando la varianza ponderada amalgama (*pooled variance*) S_p^2 y el valor crítico de la distribución t de Student con $n_1 + n_2 - 2$ grados de libertad:

   $$(\bar{X}_1 - \bar{X}_2) \pm t_{1-\alpha/2,\, n_1+n_2-2}\, S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

   donde:

   $$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

   b) Mediante simulación Monte Carlo ($B = 10\,000$), evalúe si la cobertura empírica se aproxima al nivel nominal del 95 % fijando $n_1 = 20$, $n_2 = 20$, $\mu_1 = 100$, $\mu_2 = 95$ y $\sigma = 8$.

10. Sea $X \sim \text{Binomial}(n, p)$ una variable aleatoria de conteo de éxitos en n ensayos de Bernoulli independientes con probabilidad constante de éxito p.

    a) Utilizando el Teorema del Límite Central (aproximación de Wald), exprese el intervalo de confianza aproximado del $(1 - \alpha) \times 100\,\%$ para la proporción p:

    $$\hat{p} \pm Z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \text{donde } \hat{p} = \frac{X}{n}$$

b) Ejecute un experimento Monte Carlo con $B = 10\,000$ iteraciones para evaluar la cobertura empírica con $n = 100$, $p = 0.40$ y nivel de confianza del 95 %.

11. Se tienen dos poblaciones independientes Bernoulli con probabilidades reales de éxito p_1 y p_2. Se toman muestras aleatorias de tamaños n_1 y n_2, de las cuales se obtienen $X_1 \sim \text{Binomial}(n_1, p_1)$ y $X_2 \sim \text{Binomial}(n_2, p_2)$.

    a) Defina la fórmula del intervalo de confianza asintótico para la diferencia de proporciones $p_1 - p_2$:

    $$(\hat{p}_1 - \hat{p}_2) \pm Z_{1-\alpha/2}\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

    b) Diseñe la función en `R` para obtener la cobertura simulada tras $B = 10\,000$ experimentos bajo los parámetros $n_1 = 150$, $n_2 = 120$, $p_1 = 0.65$, $p_2 = 0.50$ y $1 - \alpha = 0.95$.

12. Una firma de investigación de mercado encontró que, de una muestra de 850 consumidores, el 62 % afirmó preferir empaques biodegradables al momento de comprar productos de aseo.

    a) Construya un intervalo de confianza de 95 % para la proporción poblacional de consumidores que prefieren empaques biodegradables.

    b) ¿Piensa usted que más de la mitad de todos los consumidores prefieren este tipo de empaques? ¿Por qué?

13. El supervisor de calidad de una planta embotelladora extrae una muestra aleatoria de 18 botellas de un lote para estudiar la variabilidad del volumen de llenado. La varianza muestral obtenida es de 4.35 mililitros al cuadrado. Calcule un intervalo de confianza del 95 % para la varianza poblacional del volumen de llenado.

14. Un centro de acondicionamiento físico evalúa dos rutinas de entrenamiento midiendo el número de repeticiones que 8 atletas logran completar en cada una. Cada atleta realizó ambas rutinas y los resultados se registran como sigue:

Atleta	1	2	3	4	5	6	7	8
Rutina 1	22	18	25	20	19	24	21	23
Rutina 2	27	20	26	25	23	28	22	26

    Calcule un intervalo de confianza del 95 % para la diferencia media entre las dos rutinas, suponiendo que las diferencias se distribuyen de forma aproximadamente normal. Explique por qué es necesario el pareado en este problema.

15. A un epidemiólogo le interesa determinar la proporción de fumadores entre hombres y mujeres de cierta región. En una muestra aleatoria de 900 hombres encuentra que 288 fuman; mientras que de 950 mujeres examinadas, 209 fuman. Calcule un intervalo de confianza del 95 % para la diferencia entre la proporción de hombres y mujeres que fuman.

16. Se registran los siguientes tiempos de reacción, en segundos, de 12 participantes ante un estímulo visual:

$$0.32,\ 0.28,\ 0.35,\ 0.41,\ 0.29,\ 0.38,\ 0.33,\ 0.30,\ 0.44,\ 0.27,\ 0.36,\ 0.31$$

Suponga que los tiempos de reacción provienen de una población normal y, con base en esto, calcule el intervalo de confianza del 95 % e interprételo.

17. En una gran empresa se extrajeron muestras aleatorias independientes de 110 empleados del área comercial y de 95 empleados del área administrativa. La calificación media de desempeño de la muestra aleatoria de empleados del área comercial fue de 4.12 y la de la muestra aleatoria de empleados del área administrativa fue de 3.95. Con base en evaluaciones históricas similares, se supone que la desviación estándar poblacional del área comercial es 0.55 y que la desviación típica poblacional del área administrativa es 0.38. Calcule un intervalo de confianza de 90 %, interprete el resultado.

18. Un laboratorio compara la precisión de dos métodos para medir la concentración de un reactivo. En una muestra de 11 mediciones con el método A la desviación estándar fue de 2.4 unidades, mientras que en una muestra de 13 mediciones con el método B la desviación estándar fue de 1.1 unidades. Construya un intervalo de confianza del 90 % y concluya cuál método parece más preciso.

19. Una plataforma de streaming realiza un estudio sobre el tiempo semanal que sus usuarios dedican a ver series, en el horario de 7:00 a 10:00 de la noche. Estudios anteriores permiten suponer que la desviación estándar poblacional es de 2.8 horas. Una muestra de 45 usuarios arrojó una media de 9.2 horas. Dé una estimación mediante un intervalo de confianza del 95 % para la media poblacional del tiempo semanal dedicado a ver series en ese horario.

20. Una empresa de logística compara el tiempo de entrega, en horas, de sus paquetes en dos ciudades. En una muestra aleatoria simple de 35 envíos en Medellín la media es 26.4 horas y la desviación estándar es 6.1 horas, y en una muestra aleatoria simple independiente de 28 envíos en Cali la media es 22.1 horas y la desviación estándar es 4.8 horas.

    a) ¿Cuál es la estimación puntual de la diferencia entre el tiempo medio de entrega en Medellín y en Cali?

    b) Dé un intervalo de confianza de 95 % para la diferencia entre las dos medias poblacionales.

21. Un banco desea estimar el tiempo promedio de espera en fila de sus clientes. El archivo `espera.csv` contiene, en la columna `minutos`, el tiempo de espera registrado para una muestra aleatoria de clientes. Importe los datos en R y, verificando el supuesto que requiera, calcule e interprete un intervalo de confianza del 95 % para el tiempo promedio de espera.

22. Una universidad quiere comparar el desempeño de dos métodos de enseñanza. El archivo `calificaciones.csv` contiene la columna `metodo` (con los valores `A` y `B`) y la columna `puntaje` con la calificación obtenida por cada estudiante. Importe los datos en R, separe las dos muestras y calcule un intervalo de confianza del 95 % para la diferencia entre las calificaciones medias de los dos métodos. Indique con qué supuesto sobre las varianzas está trabajando y por qué.

23. Una empresa aplicó una encuesta de satisfacción a sus clientes. El archivo `encuesta.csv` contiene la columna `satisfecho`, codificada como 1 si el cliente está satisfecho y 0 en caso contrario. Importe los datos en R y calcule un intervalo de confianza del 90 % para la proporción poblacional de clientes satisfechos.

24. Un estudio clínico registra la presión arterial sistólica de 12 pacientes antes y después de un tratamiento. El archivo `presion.csv` contiene las columnas `antes` y `despues` para cada paciente. Importe los datos en R y calcule un intervalo de confianza del 95 % para el cambio medio en la presión arterial tras el tratamiento. Interprete el resultado y explique por qué este análisis corresponde a muestras pareadas.