Universidad Externado de Colombia

Guía del Proyecto

Asignatura: Inferencia Estadística

1. Instrucciones generales

1. El proyecto se desarrolla en grupo durante todo el semestre y se evalúa en **dos entregas**: una **Entrega intermedia** (planteamiento y análisis descriptivo) y una **Entrega final** con **sustentación oral**.
2. Cada grupo entrega un documento que desarrolle las secciones indicadas para la entrega correspondiente. El proyecto es acumulativo: la Entrega final retoma y profundiza lo trabajado en la intermedia.
3. El software del curso es **R**. Todo análisis, tabla o gráfico debe ser reproducible con las herramientas vistas en clase.
4. Se debe cuidar la ortografía y la gramática. Se restarán puntos por errores ortográficos o gramaticales.

2. Enfoque del proyecto

El proyecto tiene como propósito que el estudiante aplique, sobre un conjunto de datos real, el flujo de trabajo de un científico de datos: **formular una pregunta, explorar los datos y resolverla con herramientas inferenciales**. No se trata de reproducir fórmulas, sino de usar la inferencia para sustentar una conclusión sobre una población a partir de una muestra, comunicando la incertidumbre con criterio.
El enfoque es **inferencial, no predictivo**. El proyecto se concentra en estimar, cuantificar la incertidumbre y contrastar: comparación de grupos (diferencia de medias o de proporciones, o pruebas pareadas) y **regresión lineal simple** leída en clave inferencial —interpretación de los coeficientes, pruebas de significancia y verificación de supuestos—. La construcción de modelos predictivos, la regresión múltiple y la validación de modelos **no forman parte de este proyecto**: corresponden a *Machine Learning I*.
El trabajo tiene un peso total del **15 %** de la nota del curso y se desarrolla de forma acumulativa a lo largo del semestre, en dos entregas. La **Entrega intermedia** (sesión 19) cubre el planteamiento del problema y el análisis descriptivo de los datos elegidos; la **Entrega final** (semana de exámenes) integra el análisis inferencial completo y se acompaña de una sustentación oral. De este modo, el proyecto articula las tres etapas centrales del curso —estimación, cuantificación de la incertidumbre y contraste— en un caso aplicado y coherente.

3. Herramientas y autoría

El software oficial del curso es **R**, empleado para simular, calcular, visualizar e interpretar resultados. **Solo se considerarán válidos los resultados obtenidos mediante las técnicas y funciones estudiadas en las sesiones de clase**, dado que cada entrega es una actividad evaluativa de lo trabajado en el curso.
El proyecto es de enfoque inferencial. Cualquier análisis, tabla o gráfico que emplee métodos, modelos o librerías no vistos en clase —por ejemplo, modelos predictivos, regresión múltiple, técnicas de *machine learning* o de aprendizaje profundo— queda fuera del alcance del proyecto y **no será válido para evaluación**. Si una entrega sustituye el análisis inferencial exigido por herramientas ajenas al curso, se asumirá que no evidencia el aprendizaje evaluado y su calificación será de **1.0 sobre 5.0**.
El propósito es que el estudiante ponga en práctica lo estudiado y consolide su criterio inferencial: elegir la prueba adecuada, verificar sus supuestos e interpretar correctamente sus resultados. Si existe duda sobre si una herramienta o método es válido, se debe consultar con el profesor antes de usarlo.

4. Directrices de formato, extensión y concisión

El proyecto simula un entorno profesional real, donde la capacidad de síntesis y la claridad en la comunicación son tan importantes como el análisis técnico. Por ello, se establecen las siguientes reglas para ambas entregas:

- **Extensión del texto.** El cuerpo del informe (excluyendo portada, bibliografía, gráficos y tablas) debe tener una extensión **mínima de 3 y máxima de 5 páginas**. Documentos con menos de 3 páginas se consideran superficiales y pueden ser penalizados; documentos que excedan las 5 páginas se truncan para su evaluación (solo se leen las primeras 5) o se penalizan en la rúbrica de comunicación.
- **Gráficos y tablas.** No cuentan dentro del límite de páginas, pero **solo se evalúan aquellos que estén directamente referenciados y analizados en el texto**. Cada figura o tabla debe tener: (1) título descriptivo, (2) referencia en el texto y (3) interpretación de dos a tres líneas. La calidad de la lectura estadística prevalece sobre la cantidad de gráficas.
- **Reporte de resultados inferenciales.** Todo contraste o estimación debe reportarse de forma completa: estadístico, valor p, intervalo de confianza cuando corresponda y **una interpretación en el contexto del problema**. No basta con indicar "se rechaza / no se rechaza"; debe explicarse qué significa el resultado y con qué alcance.
- **Tablas en LaTeX.** Deben construirse con el entorno `tabular` estándar; se deben evitar tablas copiadas directamente de R o de una hoja de cálculo. Se ajustan las columnas con `p{ancho}` para permitir salto de línea.
- **Concisión y redundancia.** Se valora la escritura directa y ejecutiva. Se deben evitar párrafos de relleno, introducciones teóricas extensas (no explicar qué es un intervalo de confianza o un p-valor, sino usarlos e interpretarlos) y redundancias entre secciones.
- **Código.** El informe no debe incluir código; este se aloja en un archivo aparte (por ejemplo, un *script* o cuaderno reproducible en R), disponible en caso de que se requiera verificación. El informe es para los hallazgos y su interpretación, no para el listado del código.

El incumplimiento de estas directrices afecta la calificación final, ya que la capacidad de gestionar y comunicar la información es una competencia evaluada en el curso.

5. Tareas iniciales

5.1. Organizar el equipo de trabajo

El grupo decide su conformación y asigna roles explícitos:

- quién organiza las actividades,
- quién controla los tiempos,
- quién se comunica con el profesor cuando sea necesario,
- quién se encarga de realizar la entrega.

Esta asignación busca evitar que, por descuidos de coordinación, las entregas no se realicen a tiempo.

5.2. Elegir la base de datos

Para asegurar que se trabaja con datos reales y contextos familiares, se emplean bases tomadas de *Datos Abiertos Colombia* (`https://www.datos.gov.co/`). Se pueden usar otras bases solo si se justifica y no corresponden a un *proyecto típico*. La base debe cumplir:

- tener al menos 1000 registros;
- haber sido creada con datos reales;
- corresponder a un contexto que el grupo comprenda;

- **contener variables numéricas y categóricas**, de modo que permita comparar grupos y ajustar una regresión;
- permitir formular, al menos, **dos comparaciónes de grupos** (diferencia de medias o de proporciones) y **una o mas relaciónes entre dos variables numéricas** apta para **regresión lineal simple**.

La elección de la base condiciona todo el proyecto: antes de fijarla, conviene verificar que las preguntas de investigación previstas puedan responderse con las herramientas inferenciales del curso.

6. Entrega 1 — Planteamiento y análisis descriptivo

Momento: sesión 19 (en clase). **Peso:** 5 % (dentro del 15 % del proyecto).
Esta primera entrega cubre el **planteamiento del problema** y el **análisis descriptivo** de la base elegida. En esta etapa **aún no se realiza inferencia**: el análisis exploratorio completo se desarrolla en *Data Mining*, por lo que aquí se trabaja únicamente la descripción de los datos y la formulación de las preguntas que se responderán en la Entrega 2.

6.1. Contexto de la base de datos

- **Descripción y origen:** qué contiene la base, quién la produce y a qué población se refiere.
- **Diccionario de variables:** tabla con nombre, descripción y tipo (numérica o categórica) de las variables relevantes.
- **Unidad de observación:** qué representa cada registro y cuántos registros tiene la base.

6.2. Análisis descriptivo

- **Resúmenes numéricos:** medidas de tendencia central y de dispersión de las variables clave.
- **Distribuciones:** forma de las variables numéricas (simetría, dispersión) mediante histogramas o diagramas de caja.
- **Exploración de grupos y relaciones:** descripción preliminar de las variables que luego se usarán para comparar grupos y para la regresión (por ejemplo, comparación de una variable numérica entre categorías, o dispersión entre dos variables numéricas). Todo con carácter descriptivo, sin pruebas de hipótesis.

6.3. Preguntas de investigación

Se formulan de dos a tres preguntas claras y respondibles con las herramientas del curso. Deben estar pensadas para poder aplicar después, en la Entrega 2, al menos:

- una **comparación de grupos** (diferencia de medias o de proporciones, o comparación pareada), y
- una **relación entre dos variables numéricas** apta para **regresión lineal simple**.

6.4. Rúbrica de la Entrega 1

Criterio	Excelente (4.0–5.0)	Bueno (3.0–3.9)	Aceptable (2.0–2.9)	Deficiente (0.0–1.9)
Contexto y base de datos	Base pertinente y bien descrita. Diccionario completo y unidad de observación clara.	Base descrita con diccionario completo, con detalles menores por precisar.	Descripción superficial. Diccionario incompleto o unidad de observación confusa.	Sin descripción clara de la base ni diccionario de variables.
Análisis descriptivo	Resúmenes y distribuciones correctos, bien interpretados y pertinentes al objetivo.	Descriptivos correctos con interpretación básica.	Descriptivos incompletos o con lectura débil de los resultados.	Descriptivos ausentes o incorrectos; solo tablas crudas sin análisis.
Preguntas de investigación	Preguntas claras y respondibles, que habilitan comparación de grupos y regresión simple.	Preguntas claras, pero solo una de las dos vías inferenciales queda bien habilitada.	Preguntas vagas o difícilmente respondibles con las herramientas del curso.	Preguntas ausentes o desconectadas de los datos.
Comunicación y formato	Informe conciso, ordenado y profesional. Figuras referenciadas e interpretadas.	Informe claro, con ligera extensión o redundancia.	Informe desorganizado o con figuras sin interpretación.	Informe incompleto o que incumple el formato exigido.

7. Entrega 2 — Informe inferencial completo y sustentación

Momento: semana de exámenes (17–20 de noviembre). **Peso:** 10 % (dentro del 15 % del proyecto), con sustentación oral el mismo día.
La entrega final integra el trabajo de la Entrega 1 en un informe inferencial completo y coherente, acompañado de una **sustentación oral**. El objetivo es responder, con herramientas de inferencia, las preguntas de investigación planteadas al inicio, comunicando los resultados y su incertidumbre con criterio. Se mantienen las directrices de formato, extensión y política de herramientas de la Entrega 1.

7.1. Planteamiento formal de hipótesis

Se formulan las hipótesis nula y alternativa (H_0 y H_1) correspondientes a cada pregunta de investigación, precisando el parámetro de interés, el nivel de significancia y el tipo de contraste.

7.2. Comparación de grupos

Se aplica al menos dos contrastes de comparación —diferencia de medias (con corrección de Welch cuando corresponda), diferencia de proporciones o prueba pareada—, verificando sus supuestos y reportando estadístico, valor p e intervalo de confianza, con su interpretación en el contexto del problema.

7.3. Regresión lineal simple

Se ajusta uno vo varios modelos de regresión lineal simple con enfoque inferencial:

- **Interpretación de los coeficientes:** sentido de la pendiente y del intercepto en el contexto del problema.
- **Significancia:** prueba t sobre la pendiente y prueba F global del modelo.

- **Bondad de ajuste:** R^2 (y R^2 ajustado), con su lectura correcta.
- **Diagnóstico de supuestos:** análisis de residuos (linealidad, homocedasticidad, normalidad e independencia).

El alcance es estrictamente inferencial: **no se exige regresión múltiple ni uso predictivo**, que corresponden a *Machine Learning I*.

7.4. Conclusiones

Se responden explícitamente las preguntas de investigación de la Entrega 1 a partir de la evidencia obtenida, señalando el alcance y las limitaciones del análisis (supuestos, tamaño de muestra, posibles sesgos).

7.5. Sustentación oral

Cada grupo sustenta el proyecto el día del examen final, justificando las decisiones tomadas y respondiendo preguntas sobre el análisis. Se valora el dominio técnico, la claridad de la comunicación y la capacidad de defensa ante preguntas.

7.6. Rúbrica de la Entrega 2

Criterio	**Excelente (4.0–5.0)**	**Bueno (3.0–3.9)**	**Aceptable (2.0–2.9)**	**Deficiente (0.0–1.9)**
Hipótesis y comparación de grupos	Hipótesis bien formuladas. Contraste correcto, con supuestos verificados e interpretación en contexto.	Hipótesis y contraste correctos, con interpretación básica o supuestos poco discutidos.	Hipótesis vagas o contraste con errores. Interpretación débil.	Hipótesis ausentes o contraste incorrecto o no realizado.
Regresión lineal simple	Coeficientes, pruebas t/F, R^2 y diagnóstico de residuos correctos y bien interpretados.	Regresión correcta con interpretación básica o diagnóstico de supuestos incompleto.	Regresión con errores conceptuales o sin análisis de residuos.	Regresión ausente, incorrecta o sustituida por métodos no vistos en clase.
Conclusiones y alcance	Responden las preguntas con evidencia y discuten limitaciones con criterio.	Responden las preguntas, con discusión limitada de alcance y limitaciones.	Conclusiones genéricas o poco conectadas con los resultados.	Sin conclusiones claras o desconectadas del análisis.
Sustentación	Defensa sólida; domina el proceso y responde con claridad y rigor.	Sustentación correcta con justificación parcial de las decisiones.	Sustentación superficial; decisiones poco justificadas.	Sustentación deficiente o incoherente con el informe.
Comunicación y formato	Informe conciso y profesional. Resultados reportados completos (estadístico, p, IC) e interpretados.	Informe claro, con ligera extensión o redundancia.	Informe desorganizado o con reportes incompletos.	Informe incompleto o que incumple el formato y la política de herramientas.

8. Cronograma y evaluación

El proyecto tiene un peso total del **15 %** de la nota del curso, distribuido en dos entregas. La Entrega 2 incorpora la sustentación oral, que se realiza el día del examen final.

Entrega	**Momento**	**Contenido**	**Peso**
Entrega 1: planteamiento y descriptivo	Sesión 19 (bloque de intervalos)	Contexto de la base, análisis descriptivo y preguntas de investigación. Sin inferencia.	5 %
Entrega 2: informe inferencial y sustentación	Semana de exámenes	Hipótesis, comparación de grupos, regresión lineal simple interpretada y conclusiones. Incluye sustentación oral.	10 %
		Total del proyecto	**15 %**

La calificación de cada entrega se rige por su rúbrica respectiva (escala de 0.0 a 5.0). El incumplimiento de las directrices de formato, extensión o política de herramientas afecta la nota, ya que la comunicación y el uso correcto de las herramientas del curso son competencias evaluadas.